Machine Learning

Lecture 05 — Questions Bank

المحاضرة 5 - Linear Models II

التحدب Convexity، ضبط معدل التعلم، التصنيف الخطي الثنائي Binary Linear Classification،
والانحدار اللوجستي Logistic Regression مع دالة Sigmoid والـ Cross-Entropy Loss.

MCQ • 12 Essay • 6 Numerical 30

مع الإجابات الصحيحة والشروحات

أسئلة الاختيار من متعدد — Multiple Choice Questions (MCQ)

1. 1. If a function is convex, what can we say about its critical points? high

لو الدالة محدبة (convex)، إيه اللي نقدر نقوله عن نقاطها الحرجة (critical points)؟

A. Every critical point is a global optimum

B. Every critical point is a local optimum only

C. Critical points do not exist

D. Only saddle points exist

✅ **الإجابة الصحيحة: Every critical point is a global optimum (A)**

💡 الإجابة الصحيحة إن كل نقطة حرجة في الدالة المحدبة هي نقطة مثلى عالمية (global optimum). ده الخاصية الأساسية للتحدب اللي بتخلي Gradient Descent يلاقي الحل الأمثل.

📍 المرجع: Lecture 05 — When are Critical Points Optimal?

2. 2. A set S is convex if for any x1, x2 in S, the line segment connecting them: high

المجموعة S محدبة لو لأي نقطتين x1, x2 فيها، القطعة المستقيمة اللي بتوصّلهم:

A. Lies entirely outside S

B. Passes through the origin

C. Lies entirely within S

D. Has zero length

✅ **الإجابة الصحيحة: Lies entirely within S (C)**

💡 الخاصية الأساسية للمجموعة المحدبة: أي قطعة مستقيمة بتوصّل نقطتين فيها لازم تكون موجودة بالكامل داخل S. ده تعريف الـ convex set.

📍 المرجع: Lecture 05 — Convex Sets

3. 3. A function f is convex if the line segment between any two points on f's graph: high

الدالة f محدبة لو القطعة المستقيمة بين أي نقطتين على رسمها:

A. Lies below the graph

B. Intersects the graph exactly once

C. Is parallel to the x-axis

D. Lies above the graph

✅ **الإجابة الصحيحة: Lies above the graph (D)**

💡 في الدالة المحدبة، القطعة المستقيمة بين أي نقطتين على الرسم بتفوق الرسم (lie above). ده بيعطي شكل الـ bowl-shape. لو بتفوق تحت (lie below) تبقى concave.

📍 المرجع: Lecture 05 — Convex Functions

4. 4. The convexity condition for a function f is mathematically written as: high

شرط التحدب للدالة f بيتكتب رياضيًا كده:

A. $f((1-\lambda)x0 + \lambda x1) \geqslant (1-\lambda)f(x0) + \lambda f(x1)$

B. $f((1-\lambda)x0 + \lambda x1) \leqslant (1-\lambda)f(x0) + \lambda f(x1)$

C. $f((1-\lambda)x0 + \lambda x1) = (1-\lambda)f(x0) + \lambda f(x1)$

D. $f((1-\lambda)x0 + \lambda x1) < 0$

✅ **الإجابة الصحيحة: $f((1-\lambda)x0 + \lambda x1) \leqslant (1-\lambda)f(x0) + \lambda f(x1)$ (B)**

💡 الشرط الصحيح: $f((1-\lambda)x0 + \lambda x1) \leqslant (1-\lambda)f(x0) + \lambda f(x1)$ لـ $0 \leqslant \lambda \leqslant 1$. ده معناه إن قيمة الدالة عند المركب $\geqslant$ التركيب الخطي لقيمها.

📍 المرجع: Lecture 05 — Convex Functions

5. 5. For linear models, z = wᵀx + b is a linear function of w and b. If the loss function is a convex function of z, then: high

للنماذج الخطية، $z = w^T x + b$ دالة خطية في w و b. لو دالة الخسارة محدبة في z، يبقى:

A. It is convex only in w

B. It is convex only in b

C. It is also a convex function of w and b

D. It is non-convex in w and b

✅ **الإجابة الصحيحة: It is also a convex function of w and b (C)**

💡 لو الخسارة محدبة في z و z خطية في w و b، يبقى الخسارة محدبة في w و b كمان. ده بيسهل تحسين النموذج بالـ GD ويضمن إيجاد الحل الأمثل.

📍 المرجع: Lecture 05 — Convex Loss Functions

6. 6. What happens when the learning rate α is too small in gradient descent? high

إيه اللي بيحصل لما الـ learning rate α صغير جدًا في الـ Gradient Descent؟

A. Oscillations around the minimum

B. Instability and divergence

C. Slow progress and slow convergence

D. Immediate convergence to the optimum

✅ **الإجابة الصحيحة: Slow progress and slow convergence (C)**

💡 لو α صغير جدًا، التقدّم بيكون بطيء والتقارب (convergence) بياخد وقت طويل وعدد iterations كبير. التذبذب والعدم استقرار بيحصلوا لما α كبير جدًا.

📍 المرجع: Lecture 05 — Impact of Learning Rate

7. 7. What happens when the learning rate α is too large in gradient descent? high

إيه اللي بيحصل لما الـ learning rate α كبير جدًا؟

A. Slow convergence

B. Oscillations and possibly instability

C. Immediate convergence

D. No effect on convergence

✅ **الإجابة الصحيحة: Oscillations and possibly instability (B)**

💡 لو α كبير جدًا، الخوارزمية بتعمل oscillations (تذبذب) حوالين الـ minimum ويمكن تستقر (instability) وتعمل divergence. التقارب البطيء بيحصل لما α صغير.

📍 المرجع: Lecture 05 — Impact of Learning Rate

8. 8. What are typical good values for the learning rate α? high

إيه القيم النموذجية الجيدة لـ learning rate α؟

A. Between 0.001 and 0.1

B. Between 1 and 10

C. Between 100 and 1000

D. Negative values like −0.5

✅ **الإجابة الصحيحة: Between 0.001 and 0.1 (A)**

💡 القيم الجيدة عادة بين 0.001 و 0.1. القيم الكبيرة بتسبب oscillations/divergence، والقيم السالبة غلط لأن α لازم يكون موجب.

📍 المرجع: Lecture 05 — Finding a Good Learning Rate

9. 9. How can we determine the best value for the learning rate? high

إزاي نحدد أفضل قيمة لـ learning rate؟

A. Grid search and training curves

B. Always use 0.5

C. Random guessing only

D. Use the largest possible value

✅ **الإجابة الصحيحة: Grid search and training curves (A)**

💡 بنستخدم Grid search (نجرب قيم زي 0.1, 0.03, 0.01, ...) ونشوف الـ training curves عشان نشخّص مشاكل التحسين. ده اللي المحاضرة نصحت بيه.

📍 المرجع: Lecture 05 — Finding a Good Learning Rate

10. 10. In binary linear classification, what does the model predict? high

في التصنيف الخطي الثنائي (Binary Linear Classification)، النموذج بيتوقع إيه؟

A. A binary target $t \in \{0, 1\}$

B. A continuous-valued target

C. A multi-class target with 10 classes

D. An unordered categorical variable

✅ **الإجابة الصحيحة: A binary target $t \in \{0, 1\}$ (A)**

💡 الـ BLC بيتوقع target ثنائي $t \in \{0, 1\}$ (أو $t \in \{-1, +1\}$ للسهولة الحسابية). $t=1$ هو positive example و $t=0$ هو negative example.

📍 المرجع: Lecture 05 — Introducing Binary Linear Classification

11. 11. In the simplified binary linear classification model, the prediction y is defined as: high

في النموذج المبسّط للتصنيف الخطي الثنائي، التوقع y بيتعرف كده:

A. y = 1 if z ⩾ 0, y = 0 otherwise

B. y = 1 if z ⩾ r, y = 0 otherwise (with r != 0)

C. y = z always

D. y = 0 always

✅ **الإجابة الصحيحة: y = 1 if z ⩾ 0, y = 0 otherwise (A)**

💡 بعد تبسيط النموذج (eliminating threshold r = 0 و eliminating bias b بـ dummy feature x0 = 1)، التوقع بقى: y = 1 لو z ⩾ 0، y = 0 لو z < 0، حيث z = w⊤x.

📍 المرجع: Lecture 05 — Simplified Model

12. 12. How is the bias b eliminated in the simplified binary linear classification model? high

إزاي بيتشال الـ bias b من النموذج المبسّط للتصنيف الخطي الثنائي؟

A. By removing it completely

B. By setting b = 0 always

C. By adding a dummy feature x0 = 1, with w0 = b

D. By multiplying it by the learning rate

✅ **الإجابة الصحيحة: By adding a dummy feature x0 = 1, with w0 = b (C)**

💡 بنضيف dummy feature x0 = 1، فالوزن w0 بيبقى مكافئ للـ bias b (نفس الفكرة المستخدمة في Linear Regression). كده z = w⊤x شامل الـ bias.

📍 المرجع: Lecture 05 — Simplified Model

13. 13. The decision boundary in binary linear classification is defined by: high

حد القرار (decision boundary) في التصنيف الخطي الثنائي بيتعرف بـ:

A. {x : w⊤x = 1}

B. {x : w⊤x = r}

C. {x : w⊤x = 0}

D. {x : w⊤x = max(w)}

✅ **الإجابة الصحيحة: (C) {x : w⊤x = 0}**

💡 حد القرار هو {x : w⊤x = 0}. ده خط في D-2 أو hyperplane في الأبعاد العالية، وبيعدّي عبر نقطة الأصل لأننا شلنا الـ bias.

📍 المرجع: Lecture 05 — Visualizing NOT in Data Space

14. 14. Data is said to be linearly separable if: high

البيانات بتتوصف بـ linearly separable لو:

A. No linear decision rule can separate the examples

B. The data has more than 2 features

C. The data is normally distributed

D. A linear decision rule can perfectly separate the training examples

✅ **الإجابة الصحيحة: (D) A linear decision rule can perfectly separate the training examples**

💡 البيانات linearly separable لو فيه قاعدة قرار خطية (linear decision rule) تقدر تفصل أمثلة التدريب بشكل مثالي. زي ما اتعرض في NOT و AND.

📍 المرجع: Lecture 05 — Visualizing NOT in Data Space

15. 15. In the weight space visualization, what does each training example x specify?

high

في تصوّر الـ weight space، كل مثال تدريب x بيمثل إيه؟

A. A half-space that w must lie in to guarantee correct classification

B. A single point that w must equal

C. A line through the origin

D. A circular region around w

✅ **الإجابة الصحيحة: A half-space that w must lie in to guarantee correct classification (A)**

💡 كل مثال تدريب x بيمثل half-space (نصف فضاء) لازم w يكون جواه عشان يضمن التصنيف الصحيح. المنطقة الممكنة (feasible region) بتحقق كل القيود.

📍 المرجع: Lecture 05 — Visualizing NOT in Weight Space

16. 16. The feasible region in weight space is: high

المنطقة الممكنة (feasible region) في الـ weight space هي:

A. The region where all constraints are satisfied

B. The region where w = 0

C. The region with no constraints

D. The region outside all half-spaces

✅ **الإجابة الصحيحة: The region where all constraints are satisfied (A)**

💡 الـ feasible region هي المنطقة اللي بتحقق كل القيود (constraints) المفروضة من أمثلة التدريب. المشكلة feasible لو الـ feasible region مش فاضية (nonempty).

📍 المرجع: Lecture 05 — Visualizing NOT in Weight Space

17. 17. For the AND function, an example solution is w0 = −1.5, w1 = 1, w2 = 1. The decision boundary equation is: high

للدالة AND، حل مثالي هو w0 = −1.5, w1 = 1, w2 = 1. معادلة حد القرار هي:

A. −1.5 + x1 + x2 = 0

B. x1 + x2 = 1.5

C. w0 + w1 + w2 = 0

D. x0 + x1 + x2 = 0

✅ **الإجابة الصحيحة: (A) −1.5 + x1 + x2 = 0**

💡 حد القرار w0x0 + w1x1 + w2x2 = 0، وبما إن x0 = 1: −1.5 + x1 + x2 = 0. ده اللي ظهر في المحاضرة كـ Example Solution.

📍 المرجع: Lecture 05 — Visualizing AND in Data and Weight Spaces

18. 18. Which algorithms can be used to learn weights for a linearly separable data-set? high

أي الخوارزميات ممكن تُستخدم لتعلّم الأوزان لبيانات linearly separable؟

A. Linear programming and perceptron algorithm

B. K-means clustering and PCA

C. Decision trees and random forests

D. KNN and Naive Bayes

✅ **الإجابة الصحيحة: (A) Linear programming and perceptron algorithm**

💡 محاضرة بتذكر خيارين: Linear programming و Perceptron algorithm. الخيارات التانية خوارزميات تانية (clustering, trees) مش مخصصة لتعلم حدود خطية.

📍 المرجع: Lecture 05 — Main Takeaways on Binary Linear Classification 2/2

19. 19. The sigmoid function σ(z) maps any real value to a value in the range: high

دالة الـ sigmoid σ(z) بتحوّل أي قيمة حقيقية لقيمة في المدى:

A. [−1, 1]

B. [0, ∞)

C. [0, 1]

D. (−∞, ∞)

✅ **الإجابة الصحيحة: (C) [0, 1]**

💡 الـ sigmoid بترجع قيمة بين 0 و 1، عشان كده بتنفع لتمثيل الاحتمالات في Logistic Regression. الصيغة: σ(z) = 1 / (1 + e^(−z)).

📍 المرجع: Lecture 05 — Logistic Function / Sigmoid Function

20. 20. Despite its name, logistic regression is mainly used for: high

رغم اسمها، الانحدار اللوجستي (Logistic Regression) بيُستخدم أساسًا لـ:

A. Regression problems only

B. Clustering tasks

C. Classification problems

D. Dimensionality reduction

✅ **الإجابة الصحيحة: Classification problems (C)**

💡 رغم اسمه regression، اللوجستي بيُستخدم للتصنيف (classification). بيعمل تقدير للاحتمال، ولو الاحتمال > 0.5 بيتوقع الفئة 1، غير كده الفئة 0.

📍 المرجع: Lecture 05 — Logistic regression

21. 21. In logistic regression, the default threshold for classifying an instance as class 1 is: high

في الانحدار اللوجستي، الحد الافتراضي لتصنيف المثال كـ class 1 هو:

A. 0.0

B. 0.25

C. 0.5

D. 1.0

✅ **الإجابة الصحيحة: (C) 0.5**

💡 الحد الافتراضي هو 0.5. لو الاحتمال المقدّر ⩾ 0.5، النموذج بيتوقع class 1؛ غير كده class 0. ده اللي المحاضرة ذكرته.

📍 المرجع: Lecture 05 — Logistic regression

22. 22. Which type of logistic regression handles 3 or more unordered categories like "cat", "dog", "sheep"? high

أي نوع من الانحدار اللوجستي بيتعامل مع 3 فئات أو أكتر غير مرتبة زي "cat", "dog", "sheep"؟

A. Binomial

B. Ordinal

C. Linear

D. Multinomial

✅ **الإجابة الصحيحة: (D) Multinomial**

💡 Multinomial logistic regression بيتعامل مع 3+ فئات غير مرتبة (unordered). Binomial لفئتين بس، و Ordinal لفئات مرتبة (low, medium, high).

📍 المرجع: Lecture 05 — Types of Logistic Regression

23. 23. Ordinal logistic regression is used when the dependent variable has: medium

الانحدار اللوجستي الترتيبي (Ordinal) يُستخدم لما المتغير التابع فيه:

A. Exactly 2 categories

B. 3 or more unordered categories

C. 3 or more ordered categories like "low", "medium", "high"

D. Continuous values

✅ الإجابة الصحيحة: C) "3 or more ordered categories like "low", "medium", "high"

💡 Ordinal logistic regression يُستخدم لما الفئات مرتبة (ordered) زي low, medium, high. Binomial لفئتين، و Multinomial لفئات غير مرتبة.

📍 المرجع: Lecture 05 — Types of Logistic Regression

24. 24. The cross-entropy loss for logistic regression is given by: high

خسارة الـ cross-entropy للانحدار اللوجستي بتعطى بـ:

A. $LCE(y, t) = t \cdot \log(y) + (1-t) \cdot \log(1-y)$

B. $LCE(y, t) = (y - t)^2$

C. $LCE(y, t) = |y - t|$

D. $LCE(y, t) = -t \cdot \log(y) - (1-t) \cdot \log(1-y)$

✅ الإجابة الصحيحة: D) $LCE(y, t) = -t \cdot \log(y) - (1-t) \cdot \log(1-y)$

💡 الصيغة الصحيحة: $LCE(y, t) = -t \cdot \log(y) - (1-t) \cdot \log(1-y)$. الإجابة الأولى بدون الإشارة السالبة غلط، والباقي دوال خسارة تانية (MSE, MAE).

📍 المرجع: Lecture 05 — Gradient of Logistic Loss

25. 25. The gradient of the cross-entropy loss with respect to wj in logistic regression simplifies to: high

تدرج خسارة الـ cross-entropy بالنسبة لـ wj في الانحدار اللوجستي بتبسّط لـ:

A. (y − t) • xj

B. (t − y) • xj

C. $(y - t)^2$ • xj

D. y • t • xj

✅ الإجابة الصحيحة: (A) xj • (y − t)

💡 بعد الاشتقاق بالـ chain rule: ∂ LCE/∂ wj = (y − t) • xj. ده نفس شكل تدرج Linear Regression تقريبًا، بس y هنا مخرج الـ sigmoid.

📍 المرجع: Lecture 05 — Gradient of Logistic Loss

26. 26. The gradient descent update rule for logistic regression is: high

قاعدة تحديث الـ Gradient Descent للانحدار اللوجستي هي:

A. wj → wj + α • (1/N) • Σ(y(i) − t(i)) • xj(i)

B. wj → wj − α • (1/N) • Σ(t(i) − y(i)) • xj(i)

C. wj → α • (1/N) • Σ(y(i) − t(i)) • xj(i)

D. wj → wj − α • (1/N) • Σ(y(i) − t(i)) • xj(i)

✅ الإجابة الصحيحة: (D) wj → wj − α • (1/N) • Σ(y(i) − t(i)) • xj(i)

💡 الصيغة الصحيحة: wj → wj − α • (1/N) • Σ(y(i) − t(i)) • xj(i). بنقص α ضرب المشتقة من الوزن. الخيار التالت إشارته معكوسة (ده بيعمل زيادة في الخسارة مش نقصان).

📍 المرجع: Lecture 05 — Gradient of Logistic Loss

27. 27. The sigmoid function is described as having what shape? medium

دالة الـ sigmoid بيتوصف شكلها بـ:

A. A straight line

B. A parabola

C. A circle

D. An "S" shape

✅ **الإجابة الصحيحة: An "S" shape (D)**

💡 الـ sigmoid ليها شكل حرف S (S-shaped curve). عشان كده بتتحول القيم المتطرفة (سالبة جدًا أو موجبة جدًا) لقيم قريبة من 0 أو 1 على الترتيب.

📍 المرجع: Lecture 05 — Logistic Function – Sigmoid Function

28. 28. In a typical logistic regression training procedure, weights are initialized to: medium

في إجراء التدريب النموذجي للانحدار اللوجستي، الأوزان بتبدأ بـ:

A. Large values like 1000

B. Small random values

C. Exactly zero

D. Negative values only

✅ **الإجابة الصحيحة: Small random values (B)**

💡 الأوزان بتُهيّأ عادة لـ small random values. ده بيساعد على كسر التماثل (symmetry breaking) وبيسمح للـ GD يكتشف حلول مختلفة.

📍 المرجع: Lecture 05 — Example (Initialization step)

29. 29. What does the term z = wTx + b represent in logistic regression? high

المصطلح z = wTx + b بيمثل إيه في الانحدار اللوجستي؟

A. The probability of class 1

B. The linear combination (input to the sigmoid function)

C. The loss value

D. The gradient of the loss

✅ **الإجابة الصحيحة: The linear combination (input to the sigmoid function) (B)**

💡 z هو التركيب الخطي اللي بيدخل لدالة الـ sigmoid. الاحتمال y = σ(z) = 1/(1+e^(−z)). فـ z مش الاحتمال نفسه، لكن مدخل الـ sigmoid.

📍 المرجع: Lecture 05 — Logistic regression (How does it work?)

30. 30. If the sigmoid output for an input is exactly 0.5, what does the model typically predict? medium

لو مخرج الـ sigmoid لمُدخل هو 0.5 بالظبط، النموذج بيتوقع إيه عادة؟

A. Always class 1

B. Always class 0

C. Class 1 (since threshold is ⩾ 0.5)

D. Reject the input

✅ **الإجابة الصحيحة: Class 1 (since threshold is ⩾ 0.5) (C)**

💡 بما إن الحد هو p ⩾ 0.5 يبقى class 1، فلو المخرج = 0.5 بالظبط، النموذج بيتوقع class 1. (ملاحظة: بعض التطبيقات بتختار 0.5 = class 0، لكن المحاضرة استخدمت ⩽).

📍 المرجع: Lecture 05 — Logistic regression

الأسئلة المقالية — Essay Questions

1. 1. Define a convex set and a convex function. Why is convexity important for optimization in machine learning? high

عرّف المجموعة المحدبة (convex set) والدالة المحدبة (convex function). ليه التحدب مهم في تحسين نماذج تعلم الآلة؟

Convex set: A set S is convex if any line segment connecting two points in S lies entirely within S. Formally, for x1, x2 ∈ S, λ • x1 + (1−λ) • x2 ∈ S for 0 ⩽ λ ⩽ 1.
Convex function: A function f is convex if the line segment between any two points on f's graph lies above f's graph. Formally, f((1−λ)x0 + λx1) ⩽ (1−λ)f(x0) + λf(x1).
Importance: If a function is convex, then every critical point is a global optimum. This means gradient descent is guaranteed to find the global minimum (no local optima traps). For linear models, if the loss is convex in z = w⊤x + b, it is also convex in w and b, making optimization tractable.

📍 Reference: Lecture 05 — Convex Sets & Convex Functions

2. 2. Explain the impact of the learning rate α on gradient descent. What happens when α is too small or too large? high

اشرح تأثير الـ learning rate α على الـ Gradient Descent. إيه اللي بيحصل لما α صغير جدًا أو كبير جدًا؟

The learning rate α controls the step size at each iteration of gradient descent.
α too small: slow progress and slow convergence — the algorithm may need a very large number of iterations to reach the minimum.
α too large: oscillations around the minimum, possibly overshooting it.
α much too large: instability and divergence — the cost function may grow instead of shrink.
How to find a good value: typical good values are between 0.001 and 0.1. Use grid search (try 0.1, 0.03, 0.01, ...) and diagnose optimization problems using training curves. Alternatively, change the algorithm (e.g., line search).

📍 Reference: Lecture 05 — Impact of Learning Rate & Finding a Good Learning Rate

3. 3. Describe the simplified model for Binary Linear Classification. How are the threshold r and the bias b eliminated? high

وصف النموذج المبسّط للتصنيف الخطي الثنائي. إزاي بيتشال الـ threshold r و الـ bias b؟

Binary Linear Classification predicts a binary target $t \in \{0, 1\}$ using a linear function of inputs followed by thresholding.
General model: $z = w^\top x + b$, $y = 1$ if $z \geqslant r$, $y = 0$ if $z < r$.
Eliminating the threshold r: assume $r = 0$, so $w^\top x + b \geqslant r$ becomes $w^\top x + b' \geqslant 0$ where $b' = b - r$.
Eliminating the bias b: add a dummy feature $x_0 = 1$. The weight $w_0 = b$ acts as the bias (same trick as in linear regression).
Simplified model: $z = w^\top x$, $y = 1$ if $z \geqslant 0$, $y = 0$ if $z < 0$.

📍 Reference: Lecture 05 — Simplified Model

4. 4. Compare data space and weight space visualizations in Binary Linear Classification. What do points, lines, and half-spaces represent in each? high

قارن بين تصوّر الـ data space و الـ weight space في التصنيف الخطي الثنائي. النقاط والخطوط وأنصاف الفضاءات بتمثل إيه في كل واحد؟

Data space:
- Points represent training examples.
- A line (or hyperplane in high dimensions) represents a set of weights — the decision boundary $\{x : w^\top x = 0\}$.
- The boundary separates the data into two regions (positive vs. negative predictions).

Weight space:
- Points represent sets of values for the weights w.
- Each training example specifies a half-space that w must lie in to guarantee correct classification.
- The feasible region (where all constraints are satisfied) is the intersection of all half-spaces. The problem is feasible if this region is nonempty.

📍 Reference: Lecture 05 — Visualizing NOT/AND in Data and Weight Spaces

5. 5. Model the AND logical function using Binary Linear Classification. Give an example set of weights and derive the decision boundary. high

مثّل دالة AND المنطقية باستخدام التصنيف الخطي الثنائي. اذكر مجموعة أوزان مثالية واشتق حد القرار.

AND truth table (with dummy x0 = 1):
x0 x1 x2 | t
1 0 0 | 0
1 0 1 | 0
1 1 0 | 0
1 1 1 | 1
Model: z = w0 • x0 + w1 • x1 + w2 • x2, y = 1 if z ⩾ 0, else 0.
Constraints from training examples (need to be satisfied for correct classification):
w0 < 0 (for x = (1,0,0), t = 0)
w0 + w2 < 0 (for x = (1,0,1), t = 0)
w0 + w1 < 0 (for x = (1,1,0), t = 0)
w0 + w1 + w2 ⩾ 0 (for x = (1,1,1), t = 1)
Example solution: w0 = −1.5, w1 = 1, w2 = 1.
Decision boundary: w0 • x0 + w1 • x1 + w2 • x2 = 0 → −1.5 + x1 + x2 = 0 → x1 + x2 = 1.5.

📍 Reference: Lecture 05 — Modeling AND & Visualizing AND

6. 6. What is logistic regression? Explain why it is used for classification despite its name, and describe the role of the sigmoid function. high

إيه هو الانحدار اللوجستي؟ اشرح ليه بيُستخدم للتصنيف رغم اسمه، ووضّح دور دالة الـ sigmoid.

Logistic regression is a supervised learning algorithm used for binary classification. Despite its name containing "regression", it is mainly used for classification (it estimates the probability that an instance belongs to a particular class).
The model computes z = w⊤x + b, then applies the sigmoid function σ(z) = 1 / (1 + e^(−z)) to map z to a probability value between 0 and 1.
Role of sigmoid: it maps any real-valued input to a value in (0, 1), forming an "S"-shaped curve. This lets us interpret the output as a probability.
Classification rule: if the estimated probability ⩾ 0.5, predict class 1; otherwise predict class 0.
It's called "regression" because it is the extension of linear regression, but the sigmoid turns the continuous output into a categorical one.

📍 Reference: Lecture 05 — Logistic regression & Logistic Function

7. 7. List and briefly explain the three types of logistic regression. high

اذكر واشرح بإختصار الأنواع الثلاثة من الانحدار اللوجستي.

1) Binomial: the dependent variable has exactly 2 possible types, such as 0 or 1, Pass or Fail.
2) Multinomial: the dependent variable has 3 or more possible unordered types, such as "cat", "dog", or "sheep".
3) Ordinal: the dependent variable has 3 or more possible ordered types, such as "low", "medium", or "high".

📍 Reference: Lecture 05 — Types of Logistic Regression

8. 8. Derive the gradient of the cross-entropy loss for logistic regression. Show that ∂LCE/∂wj simplifies to (y − t) · xj. high

اشتق تدرج خسارة الـ cross-entropy للانحدار اللوجستي. وضّح إن ∂LCE/∂wj بتبسّط لـ (y − t) · xj.

Given:
LCE(y, t) = −t · log(y) − (1−t) · log(1−y)
y = σ(z) = 1 / (1 + e^(−z))
z = w⊤x
Apply the chain rule: ∂LCE/∂wj = (∂LCE/∂y) · (∂y/∂z) · (∂z/∂wj).
Step 1 — ∂LCE/∂y = −t/y + (1−t)/(1−y).
Step 2 — ∂y/∂z = y · (1−y) (the derivative of the sigmoid).
Step 3 — ∂z/∂wj = xj (since z = w⊤x is linear in wj).
Combine:
∂LCE/∂wj = [−t/y + (1−t)/(1−y)] · y · (1−y) · xj
= [−t · (1−y) + (1−t) · y] · xj
= (−t + t · y + y − t · y) · xj
= (y − t) · xj.
So ∂LCE/∂wj = (y − t) · xj — the same form as linear regression's gradient, but with y = σ(z).

📍 Reference: Lecture 05 — Gradient of Logistic Loss

9. 9. Write the gradient descent update rule for logistic regression and explain each term. high

اكتب قاعدة تحديث الـ Gradient Descent للانحدار اللوجستي واشرح كل مصطلح.

Update rule:
wj → wj − α · (1/N) · Σ_{i=1..N} (y(i) − t(i)) · xj(i)
Where:
wj is the j-th weight being updated.
α > 0 is the learning rate (controls step size).
N is the number of training examples.
y(i) = σ(w⊤x(i)) is the predicted probability for the i-th example.
t(i) is the true label (0 or 1) for the i-th example.
xj(i) is the j-th feature of the i-th example.
(1/N) · Σ(...) is the average gradient of the cross-entropy loss over all training examples.
Intuition: we move wj in the direction opposite to the average gradient (i.e., the direction that decreases the loss).

📍 Reference: Lecture 05 — Gradient of Logistic Loss

10. 10. Explain the typical training procedure for logistic regression, step by step. high

اشرح إجراء التدريب النموذجي للانحدار اللوجستي خطوة بخطوة.

1) Initialize the weights (often to small random values).
2) For each training example:
a. Calculate the predicted probability using the current weights: y = σ(w⊤x).
b. Compare this probability to the actual class label by calculating its log loss (cross-entropy loss).
3) Update the weights to minimize the loss (using gradient descent or another optimization algorithm). This means repeatedly doing Step 2 until the log loss cannot get any smaller (convergence).
4) Classification of new instances (after training): compute p = σ(w⊤x_new). If p ⩾ 0.5, predict class 1; otherwise predict class 0.

📍 Reference: Lecture 05 — Example (training & classification steps)

11. 11. Give two real-world examples where logistic regression can be applied, as mentioned in the lecture. medium

اذكر مثالين من العالم الحقيقي ممكن نطبّق فيهم الانحدار اللوجستي، زي ما المحاضرة ذكرت.

1) Business example: For an online retailer, predict which product a particular customer is most likely to buy. The data set contains past visitors and their purchases from the online retailer.
2) Medical example: Investigate whether a person is susceptible to a certain disease. The data set contains diseased and non-diseased persons as well as other medical parameters.
(Additional example from the lecture: a weather dataset with columns 'Outlook', 'Temperature', 'Humidity', 'Wind', and 'Play' (target). Categorical columns like Outlook & Windy are encoded using one-hot encoding, while numerical columns are scaled using standard scaling / z-normalization.)

📍 Reference: Lecture 05 — Examples

12. 12. Explain what happens when the data-set is not linearly separable, and how logistic regression addresses this. high

اشرح إيه اللي بيحصل لما البيانات مش linearly separable، وإزاي الانحدار اللوجستي بيتعامل مع المشكلة دي.

When the data is not linearly separable, no set of weights can perfectly classify all training examples using a linear decision rule.
Logistic regression addresses this by:
1) Defining a loss function (the cross-entropy loss $LCE(y, t) = -t \cdot \log(y) - (1-t) \cdot \log(1-y)$).
2) Finding weights that minimize the average loss over the training examples (using gradient descent), instead of trying to perfectly separate the data.
The result is a soft probabilistic prediction (between 0 and 1) rather than a hard 0/1 classification, which gracefully handles overlap between classes. The threshold 0.5 is then applied to convert probabilities into class labels.

📍 Reference: Lecture 05 — Data Isn't Linearly Separable & Logistic regression

الأسئلة الحسابية — Numerical Questions

1. 1. (Numerical) Compute the sigmoid σ(z) for z = 0. What does the result mean? high

(سؤال حسابي) احسب الـ sigmoid σ(z) لـ z = 0. إيه معنى النتيجة؟

Given: z = 0.
Formula: σ(z) = 1 / (1 + e^(−z)).
Step 1: e^(−0) = e^0 = 1.
Step 2: σ(0) = 1 / (1 + 1) = 1 / 2 = 0.5.
Result: σ(0) = 0.5.
Interpretation: when z = 0 (i.e., w⊤x + b = 0), the model is exactly on the decision boundary and assigns probability 0.5 to class 1 — maximum uncertainty. This is consistent with the threshold of 0.5.

📍 Reference: Lecture 05 — Logistic Function / Sigmoid Function

2. 2. (Numerical) For the AND function with w0 = −1.5, w1 = 1, w2 = 1, compute z and the predicted class y for the input x = (x0=1, x1=1, x2=0). high

(سؤال حسابي) لدالة AND مع w0 = −1.5, w1 = 1, w2 = 1، احسب z والفئة المتوقعة y للمُدخل x = (1, 1, 0).

Given: w = (−1.5, 1, 1), x = (1, 1, 0).
Step 1 — Compute z = w⊤x = w0 · x0 + w1 · x1 + w2 · x2.
z = (−1.5)(1) + (1)(1) + (1)(0) = −1.5 + 1 + 0 = −0.5.
Step 2 — Apply threshold: y = 1 if z ⩾ 0, else y = 0.
Since z = −0.5 < 0, y = 0.
Result: z = −0.5, y = 0 (predicted class 0).
Verification: this matches the AND truth table (input (1,1,0) → output 0).

📍 Reference: Lecture 05 — Modeling AND & Visualizing AND

3. 3. (Numerical) For the AND function with w0 = −1.5, w1 = 1, w2 = 1, verify that the input x = (1, 1, 1) is classified correctly as class 1. high

(سؤال حسابي) لدالة AND مع w0 = −1.5, w1 = 1, w2 = 1، تحقّق إن المُدخل x = (1, 1, 1) يُصنّف صح كـ class 1.

Given: w = (−1.5, 1, 1), x = (1, 1, 1).
Step 1 — Compute z = w⊤x = w0 • x0 + w1 • x1 + w2 • x2.
z = (−1.5)(1) + (1)(1) + (1)(1) = −1.5 + 1 + 1 = 0.5.
Step 2 — Apply threshold: y = 1 if z ⩾ 0, else y = 0.
Since z = 0.5 ⩾ 0, y = 1.
Result: z = 0.5, y = 1 (predicted class 1).
Verification: this matches the AND truth table (input (1,1,1) → output 1). The chosen weights correctly classify this example.

📍 Reference: Lecture 05 — Modeling AND & Visualizing AND

4. 4. (Numerical) Given a logistic regression model with weights w = (0.5, 2.0) (so w0 = 0.5, w1 = 2.0), and an input x = (1, 0.3), compute the predicted probability y = σ(w⊤x). high

(سؤال حسابي) لنموذج انحدار لوجستي بأوزان w = (0.5, 2.0) (يعني w0 = 0.5, w1 = 2.0) ومُدخل x = (1, 0.3)، احسب الاحتمال المتوقع y = σ(w⊤x).

Given: w0 = 0.5, w1 = 2.0, x0 = 1, x1 = 0.3.
Step 1 — Compute z = w⊤x = w0 • x0 + w1 • x1 = (0.5)(1) + (2.0)(0.3) = 0.5 + 0.6 = 1.1.
Step 2 — Compute σ(z) = 1 / (1 + e^(−z)) = 1 / (1 + e^(−1.1)).
Step 3 — e^(−1.1) ≈ 0.3329.
Step 4 — σ(1.1) = 1 / (1 + 0.3329) = 1 / 1.3329 ≈ 0.7503.
Result: y ≈ 0.75.
Interpretation: the model assigns probability ~0.75 to class 1. Since 0.75 ⩾ 0.5, the predicted class is 1.

📍 Reference: Lecture 05 — Logistic regression (How does it work?)

5. 5. (Numerical) For a logistic regression model, the predicted probability is y = 0.8 and the true label is t = 1. Compute the cross-entropy loss LCE(y, t). high

(سؤال حسابي) لنموذج انحدار لوجستي، الاحتمال المتوقع y = 0.8 والفئة الحقيقية t = 1. احسب خسارة الـ cross-entropy LCE(y, t).

Given: y = 0.8, t = 1.
Formula: LCE(y, t) = −t · log(y) − (1−t) · log(1−y).
Step 1 — Substitute: LCE = −(1) · log(0.8) − (1−1) · log(1−0.8).
Step 2 — Simplify: LCE = −log(0.8) − 0 · log(0.2) = −log(0.8).
Step 3 — Compute log(0.8) ≈ −0.2231 (natural log).
Step 4 — LCE ≈ −(−0.2231) = 0.2231.
Result: LCE(0.8, 1) ≈ 0.2231.
Interpretation: the loss is small because the prediction (0.8) is close to the true label (1). If y had been 0.99, the loss would be even smaller; if y had been 0.1, the loss would be large (~2.3).

📍 Reference: Lecture 05 — Gradient of Logistic Loss

6. 6. (Numerical) In a logistic regression training step, the current weight is wj = 0.4, the predicted probability is y = 0.7, the true label is t = 1, the feature value is xj = 2.0, and the learning rate is α = 0.1. Compute the new value of wj after one gradient descent update. high

(سؤال حسابي) في خطوة تدريب للانحدار اللوجستي، الوزن الحالي wj = 0.4، الاحتمال المتوقع y = 0.7، الفئة الحقيقية t = 1، قيمة الميزة xj = 2.0، ومعدل التعلم α = 0.1. احسب القيمة الجديدة لـ wj بعد تحديث واحد.

Given: wj = 0.4, y = 0.7, t = 1, xj = 2.0, α = 0.1.
Update rule (for a single example): wj_new = wj − α · (y − t) · xj.
Step 1 — Compute the gradient term: (y − t) · xj = (0.7 − 1) · 2.0 = (−0.3) · 2.0 = −0.6.
Step 2 — Multiply by α: α · (−0.6) = 0.1 · (−0.6) = −0.06.
Step 3 — Update: wj_new = 0.4 − (−0.06) = 0.4 + 0.06 = 0.46.
Result: wj_new = 0.46.
Interpretation: because y < t (model under-predicted), the gradient (y − t) is negative, so subtracting a negative value increases wj. This moves the prediction closer to the true label (t = 1).

📍 Reference: Lecture 05 — Gradient of Logistic Loss