Machine Learning

Lecture 03 — Linear Regression — Question Bank

Part 1: Multiple Choice (25)

1. What is the task of linear regression, as stated in the lecture?

ما هي مهمة الانحدار الخطي (linear regression) كما ورد في المحاضرة؟

A. Group unlabeled data into clusters
B. Predict scalar-valued targets (for example stock prices)
C. Classify images into discrete categories
D. Compress data into fewer dimensions

✅ **الإجابة الصحيحة: B. Predict scalar-valued targets (for example stock prices)**

💡 ليه صح: المهمة هي التنبؤ بقيم مستهدفة عددية (scalar-valued targets) مثل أسعار الأسهم، والبنية هي دالة خطية للمدخلات. التجميع والتصنيف وضغط البيانات مهام أخرى.

📍 المرجع: Lecture 03 — Slide 2: Linear Regression

2. In the modular approach to ML, which component expresses a preference over different models?

في النهج المعياري (modular) للتعلم الآلي، أي مكوّن يعبّر عن تفضيل بين النماذج المختلفة؟

A. The model
B. The loss function
C. The optimization algorithm
D. The regularizer

✅ **الإجابة الصحيحة: D. The regularizer**

💡 ليه صح: الـ regularizer يعبّر عن التفضيل بين النماذج (قيد أو عقوبة). الـ model يصف العلاقات بين المتغيرات، والـ loss function تقيس مدى ملاءمة النموذج للبيانات، والـ optimization algorithm تُستخدم لإيجاد النموذج الأمثل.

📍 المرجع: Lecture 03 — Slide 3: A Modular Approach to ML

3. In the supervised learning setup, what is the objective?

في إعداد التعلم المُشرَف (supervised learning)، ما هو الهدف؟

A. Learn a function f: X -> T from the data such that t is approximately y = f(x)
B. Find clusters in X without using the targets t
C. Maximize the number of features in x
D. Make y exactly equal to x for every example

✅ **الإجابة الصحيحة: A. Learn a function f: X -> T from the data such that t is approximately y = f(x)**

💡 ليه صح: الهدف تعلّم دالة f: X -> T من البيانات D = {(x(i), t(i))} بحيث يكون t قريبًا من y = f(x). الاختيار الثاني وصف للتعلم غير المُشرَف.

📍 المرجع: Lecture 03 — Slide 4: Supervised Learning Setup

4. In the simple linear regression model Y = b0 + b1 X, what does b1 represent?

في نموذج الانحدار الخطي البسيط Y = b0 + b1 X، ماذا تمثل b1؟

A. The y-intercept
B. The dependent variable
C. The slope of the line
D. The error term

✅ **الإجابة الصحيحة: C. The slope of the line**

💡 ليه صح: b1 هي ميل الخط (slope) وتساوي Δy/Δx. أما b0 فهي المقطع y-intercept، وY هو المتغير التابع.

📍 المرجع: Lecture 03 — Slide 6: Simple Linear Regression Model

5. In the simple linear regression model Y = b0 + b1 X, what does b0 represent?

في النموذج Y = b0 + b1 X، ماذا تمثل b0؟

A. The slope of the line
B. The y-intercept
C. The independent variable
D. The residual

✅ **الإجابة الصحيحة: B. The y-intercept**

💡 ليه صح: b0 هي المقطع (y-intercept) أي قيمة y عند x = 0. الميل هو b1، والمتغير المستقل هو x.

📍 المرجع: Lecture 03 — Slide 6: Simple Linear Regression Model

6. Why is the model Y = b0 + b1 X called 'simple'?

لماذا يُسمّى النموذج Y = b0 + b1 X 'بسيطًا' (simple)؟

A. Because it has only one X
B. Because it has no parameters
C. Because it has no error term
D. Because it uses the squared loss

✅ **الإجابة الصحيحة: A. Because it has only one X**

💡 ليه صح: لأنه يحتوي على متغير مستقل واحد فقط X. وجود المعاملات والخطأ والـ squared loss لا علاقة له بكلمة simple.

📍 المرجع: Lecture 03 — Slide 7: Simple Linear Model

7. What does 'linear in the parameters' mean?

ماذا تعني عبارة 'linear in the parameters'؟

A. X appears only in the first power
B. The model has only one parameter
C. The data points lie exactly on a line
D. No parameter appears as an exponent or is multiplied or divided by another parameter

✅ **الإجابة الصحيحة: D. No parameter appears as an exponent or is multiplied or divided by another parameter**

💡 ليه صح: تعني أن أي معامل لا يظهر كأس ولا يُضرب أو يُقسم على معامل آخر. الاختيار الأول يصف 'linear in the predictor variable' وهو شرط مختلف.

📍 المرجع: Lecture 03 — Slide 7: Simple Linear Model

8. What does 'linear in the predictor variable (X)' mean?

ماذا تعني عبارة 'linear in the predictor variable (X)'؟

A. No parameter is multiplied by another parameter
B. The model has exactly one parameter
C. X appears only in the first power
D. X is always positive

✅ **الإجابة الصحيحة: C. X appears only in the first power**

💡 ليه صح: تعني أن X يظهر بالأس الأول فقط (بدون X تربيع مثلًا). الاختيار الأول يخص الخطية في المعاملات.

📍 المرجع: Lecture 03 — Slide 7: Simple Linear Model

9. In the scikit-learn example (Example 2), which attribute of the fitted LinearRegression model gives the slope?

في مثال (Example 2) scikit-learn، أي خاصية في نموذج LinearRegression بعد التدريب تعطي الميل (slope)؟

A. model.intercept_
B. model.coef_[0]
C. model.predict
D. model.fit

✅ **الإجابة الصحيحة: B. model.coef_[0]**

💡 ليه صح: الكود يطبع Slope باستخدام model.coef_[0] وIntercept باستخدام model.intercept_. أما fit وpredict فهما دالتان للتدريب والتنبؤ وليستا قيم المعاملات.

📍 المرجع: Lecture 03 — Example 2: Linear Regression in Public Policy

10. In the 'Minimizing error' slide, what are the sums of squared errors of the fitted line and of the horizontal line Y = mean(Y)?

في شريحة 'Minimizing error'، كم مجموع مربعات الأخطاء للخط المُلائم وللخط الأفقي Y = mean(Y)؟

A. 20.43 for the fitted line and 1647.33 for the mean line
B. 1647.33 for the fitted line and 20.43 for the mean line
C. Both are equal to 20.43
D. Both are equal to 1647.33

✅ **الإجابة الصحيحة: A. 20.43 for the fitted line and 1647.33 for the mean line**

💡 ليه صح: الخط المُلائم (least squares) أعطى 20.43 بينما الخط الأفقي عند المتوسط أعطى 1647.33، أي أن خط least squares هو الذي يصغّر الخطأ. الاختيار الثاني معكوس.

📍 المرجع: Lecture 03 — Slide 12: Minimizing error

11. What does the least squares method minimize?

ماذا تُصغّر طريقة المربعات الصغرى (least squares)؟

A. The sum of the absolute x values
B. The number of data points
C. The sum of squared errors, sum of (y_i - b0 - b1 x_i)^2
D. The slope of the line

✅ **الإجابة الصحيحة: C. The sum of squared errors, sum of (y_i - b0 - b1 x_i)^2**

💡 ليه صح: تُصغّر مجموع مربعات الأخطاء Σ(yi − β0 − β1xi)² وبُنتج منه الخط ŷ = β0 + β1x. لا تصغّر الميل ولا عدد النقاط.

📍 المرجع: Lecture 03 — Slide 11: Least Squares

12. How is the residual of the i-th point defined?

كيف يُعرَّف الـ residual للنقطة رقم i؟

A. x_i - mean(x)
B. y_hat_i - x_i
C. y_i + y_hat_i
D. R_i = y_i - y_hat_i

✅ **الإجابة الصحيحة: D. R_i = y_i - y_hat_i**

💡 ليه صح: الـ residual هو الفرق بين القيمة الحقيقية والمتوقعة: Ri = yi − ŷi. وفي دالة الخسارة لاحقًا في المحاضرة يُكتب كـ y − t (التنبؤ ناقص الهدف) والمقصود نفس الحجم.

📍 المرجع: Lecture 03 — Slide 11: Least Squares

13. If we assume a normal error, how should the residuals look?

إذا افترضنا أن الخطأ طبيعي (normal)، كيف يجب أن تبدو البواقي (residuals)؟

A. All equal to zero
B. Approximately normal
C. Always increasing
D. Always positive

✅ **الإجابة الصحيحة: B. Approximately normal**

💡 ليه صح: الشريحة تنص على أنه لو افترضنا خطأ طبيعيًا فالبواقي يجب أن تبدو طبيعية التوزيع. لا يمكن أن تكون كلها صفرًا لأن النقاط ليست على خط واحد.

📍 المرجع: Lecture 03 — Slide 11: Least Squares

14. Which formula gives the least squares slope estimate?

أي صيغة تعطي تقدير الميل بطريقة المربعات الصغرى؟

A. b1 = SSxy / SSx
B. b1 = SSx / SSxy
C. b1 = SSxy * SSx
D. b1 = SSxy - SSx

✅ **الإجابة الصحيحة: A. b1 = SSxy / SSx**

💡 ليه صح: الميل = SSxy / SSx حيث $SSxy = \Sigma(xi - \bar{x})(yi - \bar{y})$ و$SSx = \Sigma(xi - \bar{x})^2$. القسمة بالعكس أو الضرب أو الطرح غير صحيحة.

📍 المرجع: Lecture 03 — Slide 13: The Simple Linear Regression Model

15. Which formula gives the least squares intercept estimate?

أي صيغة تعطي تقدير المقطع (intercept) بطريقة المربعات الصغرى؟

A. b0 = y_bar + b1 * x_bar
B. b0 = x_bar - b1 * y_bar
C. b0 = y_bar - b1 * x_bar
D. b0 = b1 / x_bar

✅ **الإجابة الصحيحة: C. b0 = y_bar - b1 * x_bar**

💡 ليه صح: المقطع = $\bar{y} - \beta 1 \cdot \bar{x}$، أي أن خط الانحدار يمر بنقطة المتوسطات. الاختيارات الأخرى تبدّل المتغيرات أو الإشارة.

📍 المرجع: Lecture 03 — Slide 13: The Simple Linear Regression Model

16. Which expression equals SSx in the lecture?

أي تعبير يساوي SSx في المحاضرة؟

A. Sum of (x_i - x_bar)(y_i - y_bar)
B. Sum of y_i^2 - (sum of y_i)^2 / n
C. (sum of x_i)^2 / n
D. Sum of (x_i - x_bar)^2 = sum of x_i^2 - (sum of x_i)^2 / n

✅ **الإجابة الصحيحة: D. Sum of (x_i - x_bar)^2 = sum of x_i^2 - (sum of x_i)^2 / n**

💡 ليه صح: $SSx = \Sigma(x_i - \bar{x})^2 = \Sigma x_i^2 - (\Sigma x_i)^2/n$. الاختيار الأول هو SSxy، والثاني خاص بـ y، والثالث جزء فقط من الصيغة.

📍 المرجع: Lecture 03 — Slide 13: The Simple Linear Regression Model

17. In the education-income example the slope is 3.74. How is it interpreted?

في مثال التعليم والدخل الميل = 3.74. كيف يُفسَّر؟

A. On average, each additional year of education raises income by $3.74 thousand
B. Income is $3.74 thousand when education is zero
C. Education falls by 3.74 years for each $1000 of income
D. 3.74 percent of people have a degree

✅ **الإجابة الصحيحة: A. On average, each additional year of education raises income by $3.74 thousand**

💡 ليه صح: الميل يعني أنه في المتوسط كل سنة تعليم إضافية ترفع الدخل بمقدار 3.74 ألف دولار (الدخل بالآلاف). الاختيار الثاني تفسير للمقطع وليس الميل.

📍 المرجع: Lecture 03 — Slide 18: The Least Squares Regression Line

18. In the same example the intercept is -13.93. According to the lecture, what is this value?

في نفس المثال المقطع = -13.93. ما هذه القيمة حسب المحاضرة؟

A. The average income of everyone in the sample
B. The expected income at zero education, which is meaningless here
C. The slope of the line
D. The standard error of the estimate

✅ **الإجابة الصحيحة: B. The expected income at zero education, which is meaningless here**

💡 ليه صح: هي الدخل المتوقع لشخص مستوى تعليمه صفر، وهي قيمة بلا معنى هنا (دخل سالب). متوسط الدخل في العينة هو 30.2 وليس -13.93.

📍 المرجع: Lecture 03 — Slide 18: The Least Squares Regression Line

19. In the education-income example, which variable is the dependent variable?

في مثال التعليم والدخل، أي متغير هو المتغير التابع (dependent)؟

A. Education
B. The sample size
C. Income
D. The intercept

✅ **الإجابة الصحيحة: C. Income**

💡 ليه صح: المتغير التابع هو ما نريد التنبؤ به وتحليله وهو الدخل (y)، والتعليم هو المتغير المستقل (x) الذي يُفترض أنه يؤثر في الدخل.

📍 المرجع: Lecture 03 — Slide 15: Dependent and Independent Variables

20. In the multi-feature linear model y = w^T x + b, what are the parameters?

في النموذج الخطي متعدد الخصائص y = w^T x + b، ما هي المعاملات (parameters)؟

A. The features x and the targets t
B. Only the target t
C. The loss and the regularizer
D. The weights w and the bias (intercept) b

✅ **الإجابة الصحيحة: D. The weights w and the bias (intercept) b**

💡 ليه صح: المعاملات هي الأوزان w والـ bias/intercept b. أما x فهي الخصائص (المدخلات) وt هو الهدف، وهما بيانات وليسا معاملات.

📍 المرجع: Lecture 03 — Slide 19: Model

21. The squared error loss is L(y, t) = 1/2 (y - t)^2. Why is the factor 1/2 used?

دالة الخسارة المربعة L(y, t) = 1/2 (y - t)^2. لماذا يُستخدم العامل 1/2؟

A. It makes calculations convenient
B. It keeps the loss below 1
C. It converts the loss into a probability
D. It removes the need for the residual

✅ **الإجابة الصحيحة: A. It makes calculations convenient**

💡 ليه صح: المحاضرة تذكر أن الـ 1/2 يجعل الحسابات مريحة (عند الاشتقاق يلغي الأس 2). لا يجعل الخسارة أقل من 1 ولا يحوّلها إلى احتمال.

📍 المرجع: Lecture 03 — Slide 20: Loss Function

22. What is a cost function, according to the lecture?

ما هي دالة التكلفة (cost function) حسب المحاضرة؟

A. The loss for a single example
B. The loss function averaged over all training examples (the empirical or average loss)
C. The number of parameters in the model
D. The time needed to train the model

✅ الإجابة الصحيحة: B. The loss function averaged over all training examples (the empirical or average loss)

💡 ليه صح: هي دالة الخسارة مُتوسَّطة على كل أمثلة التدريب وتسمى أيضًا empirical أو average loss. الخسارة لمثال واحد هي الـ loss function.

📍 المرجع: Lecture 03 — Slide 20: Loss Function

23. Why is vectorized code such as y = np.dot(w, x) + b preferred over Python loops?

لماذا يُفضَّل الكود المتجه (vectorized) مثل y = np.dot(w, x) + b على حلقات Python؟

A. It uses more memory, so it is more accurate
B. It removes the bias term
C. It is simpler and much faster (less interpreter overhead, optimized linear algebra libraries, GPU support)
D. It works only with one feature

✅ الإجابة الصحيحة: C. It is simpler and much faster (less interpreter overhead, optimized linear algebra libraries, GPU support)

💡 ليه صح: لأنه أبسط وأسهل قراءة وأسرع بكثير: يقلل عبء مفسر Python ويستخدم مكتبات جبر خطي محسّنة ودعمًا من العتاد، والضرب المصفوفي سريع على GPU. لا علاقة له بالدقة أو الـ bias.

📍 المرجع: Lecture 03 — Slides 22-23: Loops vs Vectorized Code

24. After adding a column of 1s to the design matrix X, how are the predictions for the whole dataset written?

بعد إضافة عمود من الآحاد إلى مصفوفة التصميم X، كيف تُكتب التنبؤات لكل مجموعة البيانات؟

A. y = X + w
B. y = X^T w^T
C. y = w / X
D. y = Xw, with X in R^(N x (D+1)) and w in R^(D+1)

✅ الإجابة الصحيحة: D. y = Xw, with X in R^(N x (D+1)) and w in R^(D+1)

💡 ليه صح: ندمج الـ bias مع الأوزان فيصبح w = (b, w1, ..., wD) وتصبح y = Xw حيث X أبعادها N x (D+1). باقي الصيغ لا تحقق أبعاد الضرب.

📍 المرجع: Lecture 03 — Slide 26: Combining Bias and Weights

25. For J = 1/2 ||y - t||^2 without the 1/N normalizer, what is true about the minimizer?

بالنسبة لـ J = 1/2 ||y - t||^2 بدون المعامل 1/N، ما الصحيح عن النقطة المُصغِّرة (minimizer)؟

A. It does not depend on N (although the optimization might)
B. It depends strongly on N
C. It is always zero
D. It cannot be found

✅ **الإجابة الصحيحة: A. It does not depend on N (although the optimization might)**

💡 ليه صح: الشريحة تنص على أن الـ minimizer لا يعتمد على N (لكن عملية الـ optimization قد تتأثر). هذه الصيغة تقابل مجموع الخسائر وليس متوسطها.

📍 المرجع: Lecture 03 — Slide 25: Computing Squared Error Cost

Part 2: Essay and Problems (15)

Essay 1. Explain the supervised learning setup and the modular approach to ML.

اشرح إعداد التعلم المُشرَف والنهج المعياري (modular) للتعلم الآلي.

Model answer:

Supervised learning: input x in X is a vector of features, target t in T, and the data is D = {(x(i), t(i)) for i = 1, ..., N}. The objective is to learn a function f: X -> T from the data such that t is approximately y = f(x).

Modular approach: choose a model describing relationships between variables; define a loss function quantifying how well the model fits the data; choose a regularizer expressing a preference over different models.

Then fit a model that minimizes the loss function and satisfies the regularizer's constraint or penalty, possibly using an optimization algorithm.

📍 المرجع: Lecture 03 — Slides 3-4

Essay 2. Describe the simple linear regression model and explain what 'simple', 'linear in the parameters' and 'linear in the predictor' mean.

صِف نموذج الانحدار الخطي البسيط واشرح معنى simple وlinear in the parameters وlinear in the predictor.

Model answer:

Model: Y = b0 + b1 X, where y is the dependent variable, x is the independent variable, b0 is the y-intercept and b1 is the slope of the line (slope = change in y over change in x).

Simple: there is only one X.

Linear in the parameters: no parameter appears as an exponent or is multiplied or divided by another parameter.

Linear in the predictor variable (X): X appears only in the first power.

Regression analysis estimates a functional relationship between X and Y, and the regression equation is used to predict a value of Y for a given X.

📍 المرجع: Lecture 03 — Slides 5-8

Essay 3. Explain the difference between a mathematical and a statistical relation, and why an error term is needed.

اشرح الفرق بين العلاقة الرياضية والعلاقة الإحصائية ولماذا نحتاج حد الخطأ.

Model answer:

In a mathematical relation all points lie exactly on the line y = -5.3562 + 3.3988x. In a statistical relation the scatterplot shows that the points are not on a line.

So, in addition to the relationship Y = b0 + b1 X, there is an error term, and the actual response is the line plus an error.

The Y's are the response (dependent) variable and the x's are the independent variables.

The line is estimated by least squares, which finds the line that minimizes the errors.

📍 المرجع: Lecture 03 — Slides 9-10

Essay 4. Explain the least squares method and how the slope and intercept are computed.

اشرح طريقة المربعات الصغرى (least squares) وكيف يُحسب الميل والمقطع.

Model answer:

Least squares minimizes the sum of squared errors: sum of (y_i - b0 - b1 x_i)^2, giving the fitted line y_hat = b0_hat + b1_hat x.

The residuals R_i = y_i - y_hat_i should look normal if a normal error is assumed.

Slope: b1_hat = SSxy / SSx. Intercept: b0_hat = y_bar - b1_hat * x_bar.

SSx = sum of (x_i - x_bar)^2 = sum of x_i^2 - (sum of x_i)^2 / n; SSxy = sum of (x_i - x_bar)(y_i - y_bar) = sum of x_i y_i - (sum of x_i)(sum of y_i) / n.

Example: the fitted line has a sum of squared errors of 20.43, while the horizontal line Y = mean(Y) has 1647.33.

📍 المرجع: Lecture 03 — Slides 11-13

Essay 5. Describe the education and income example and interpret the regression coefficients.

صِف مثال التعليم والدخل وفسّر معاملات الانحدار.

Model answer:

An economist samples 10 individuals and records education (years) and income (in $1000s) to find the least squares line. Income (y) is the dependent variable and education (x) the independent variable that most affects income.

Sums: sum x = 118, sum x^2 = 1450, sum y = 302, sum xy = 3779. SSxy = 215.4, SSx = 57.6, so slope = 215.4 / 57.6 = 3.74 and intercept = 30.2 - 3.74 * 11.8 = -13.93.

Line: y_hat = -13.93 + 3.74 x.

Slope: on average each additional year of education raises income by $3.74 thousand. Intercept: the expected income at zero education, which is meaningless here.

📍 المرجع: Lecture 03 — Slides 14-18

Essay 6. Describe the multi-feature linear model, its parameters and why it is useful.

صِف النموذج الخطي متعدد الخصائص ومعاملاته ولماذا هو مفيد.

Model answer:

Model: a linear function of the features x = (x_1, ..., x_D) in R^D that makes a prediction y in R of the target t in R: y = f(x) = sum over j of w_j x_j + b = w^T x + b.

Parameters are the weights w and the bias or intercept b.

We want the prediction to be close to the target: y is approximately t.

It is a highly interpretable model, which is useful for debugging.

📍 المرجع: Lecture 03 — Slide 19: Model

Essay 7. Define the loss function and the cost function for linear regression.

عرّف دالة الخسارة (loss) ودالة التكلفة (cost) في الانحدار الخطي.

Model answer:

The loss function L(y, t) defines how badly the algorithm's prediction y fits the target t for some example x.

Squared error loss: L(y, t) = 1/2 (y - t)^2, where y - t is the residual and we want to minimize its magnitude; the factor 1/2 makes calculations convenient.

The cost function is the loss averaged over all training examples (the empirical or average loss): J(w, b) = 1/(2N) * sum over i of (y(i) - t(i))^2 = 1/(2N) * sum over i of (w^T x(i) + b - t(i))^2.

Without the 1/N normalizer J corresponds to the sum of losses; the minimizer does not depend on N.

📍 المرجع: Lecture 03 — Slides 20 and 25

Essay 8. Explain vectorization and its benefits, comparing a loop with vectorized code.

اشرح الـ vectorization ومميزاته مع مقارنة الحلقة بالكود المتجه.

Model answer:

Loop version for one data point: y = b; for j in range(M): y += w[j] * x[j]. Excessive super/sub scripts are hard to work with and Python loops are slow.

Vectorized version: express algorithms with vectors and matrices, w = (w_1, ..., w_D)^T and x = (x_1, ..., x_D)^T, so y = w^T x + b, written in code as y = np.dot(w, x) + b.

Benefits: the code is simpler and more readable with no dummy variables or indices; it is much faster because it cuts down Python interpreter overhead, uses highly optimized linear algebra libraries with hardware support, and matrix multiplication is very fast on a GPU.

📍 المرجع: Lecture 03 — Slides 22-23

Essay 9. Explain how predictions for the whole dataset are computed using the design matrix, and how the bias is combined with the weights.

اشرح كيف تُحسب تنبؤات كل مجموعة البيانات باستخدام مصفوفة التصميم وكيف يُدمج الـ bias مع الأوزان.

Model answer:

Put the training examples into a design matrix X (one row per example) and the targets into the target vector t. The predictions for the whole dataset are y = Xw + b1, where 1 is a vector of ones.

The squared error cost across the dataset is J = 1/(2N) ||y - t||^2.

To combine the bias and the weights, add a column of 1s to the design matrix: X in R^(N x (D+1)) and w = (b, w_1, ..., w_D) in R^(D+1). The predictions become simply y = Xw.

📍 المرجع: Lecture 03 — Slides 24-26

Essay 10. Explain the two Python examples in the lecture (scipy linregress and scikit-learn LinearRegression).

اشرح مثالَي Python في المحاضرة (scipy linregress وscikit-learn LinearRegression).

Model answer:

Example 1: the age and speed of 13 cars are plotted with plt.scatter. Then stats.linregress(x, y) returns slope, intercept, r, p and std_err; a function myfunc(x) = slope * x + intercept maps every x to a predicted value, and plt.plot draws the regression line over the scatter. The printed loss is 0.428.

Example 2 (public policy): government spending on employment programs is used to predict the unemployment rate. The arrays are reshaped, a LinearRegression model is created and trained with model.fit(spending, unemployment).

model.predict([[95]]) predicts the unemployment rate for a new spending value, model.coef_[0] gives the slope and model.intercept_ gives the intercept.

📍 المرجع: Lecture 03 — Examples (age/speed and public policy)

Problem 11. Education-income example: using sum x = 118, sum x^2 = 1450, sum y = 302, sum xy = 3779 and n = 10, compute SSx, SSxy, the slope and the intercept, then predict the income of a person with 12 years of education.

مثال التعليم والدخل: باستخدام Σx = 118 وΣx² = 1450 وΣy = 302 وΣxy = 3779 وn = 10، احسب SSx وSSxy والميل والمقطع ثم تنبأ بدخل شخص تعليمه 12 سنة.

Model answer:

Formulas: SSx = sum x^2 - (sum x)^2 / n; SSxy = sum xy - (sum x)(sum y) / n; b1 = SSxy / SSx; b0 = y_bar - b1 * x_bar.

SSxy = 3779 - (118)(302) / 10 = 3779 - 3563.6 = 215.4.

SSx = 1450 - (118)^2 / 10 = 1450 - 1392.4 = 57.6.

b1 = 215.4 / 57.6 = 3.74. b0 = 302/10 - 3.74 * (118/10) = 30.2 - 44.13 = -13.93.

Line: y_hat = -13.93 + 3.74 x. For x = 12: y_hat = -13.93 + 44.88 = 30.95, i.e. about $30.95 thousand.

📍 المرجع: Lecture 03 — Slides 16-18

Problem 12. Public policy example: for spending x = 50, 60, ..., 120 (million $) and unemployment y = 9.5, 9.0, 8.7, 8.0, 7.8, 7.2, 6.8, 6.5 (%), compute the least squares line by hand and predict the unemployment rate for a spending of 95.

مثال السياسة العامة: للإنفاق x = 50 و60 ... و120 (مليون دولار) والبطالة y = 9.5 و9.0 و8.7 و8.0 و7.8 و7.2 و6.8 و6.5 (%)، احسب خط least squares يدويًا وتنبأ بنسبة البطالة عند إنفاق 95.

Model answer:

Formulas: SSx, SSxy, b1 = SSxy / SSx, b0 = y_bar - b1 * x_bar.

n = 8: sum x = 680, so x_bar = 85; sum y = 63.5, so y_bar = 7.9375; sum x^2 = 62000; sum xy = 5214.

SSx = 62000 - 680^2 / 8 = 62000 - 57800 = 4200. SSxy = 5214 - (680)(63.5) / 8 = 5214 - 5397.5 = -183.5.

b1 = -183.5 / 4200 = -0.0437. b0 = 7.9375 - (-0.0437)(85) = 11.65.

Line: y_hat = 11.65 - 0.0437 x. For x = 95: y_hat = 11.65 - 4.15 = about 7.50 percent. The negative slope means more spending is associated with lower unemployment (this is what model.coef_[0] and model.predict([[95]]) return in the code).

📍 المرجع: Lecture 03 — Example 2: Linear Regression in Public Policy

Problem 13. A model predicts y = (3, 5, 2, 7) for four examples whose targets are t = (2, 5, 4, 6). Compute the cost J = 1/(2N) * sum of (y - t)^2.

نموذج تنبأ بـ y = (3, 5, 2, 7) لأربعة أمثلة أهدافها t = (2, 5, 4, 6). احسب التكلفة J = 1/(2N) * Σ(y - t)².

Model answer:

Formula: J = 1/(2N) * sum of (y(i) - t(i))^2, with N = 4.

Residuals y - t: 1, 0, -2, 1.

Squares: 1, 0, 4, 1, whose sum is 6.

J = 6 / (2 * 4) = 0.75.

📍 المرجع: Lecture 03 — Slide 20: Loss Function

Problem 14. A linear model has w = (2, -1, 0.5) and b = 1. Compute the prediction for x = (3, 4, 2). Also give the shapes of X and w if there are N = 100 examples and D = 5 features and the bias is combined with the weights.

نموذج خطي فيه w = (2, -1, 0.5) و b = 1. احسب التنبؤ لـ x = (3, 4, 2). وأعطِ أبعاد X و w لو N = 100 و D = 5 مثال خصائص مع دمج الـ bias في الأوزان.

Model answer:

Formula: y = w^T x + b.

y = 2*3 + (-1)*4 + 0.5*2 + 1 = 6 - 4 + 1 + 1 = 4 (in code: np.dot(w, x) + b).

With the bias combined and a column of 1s added: X is in R^(N x (D+1)) = 100 x 6 and w is in R^(D+1), a vector of length 6, so that y = Xw.

📍 المرجع: Lecture 03 — Slides 19, 22 and 26

Problem 15. Decision tree quiz: the training set below classifies names as location or person. Attribute 1 is 'first name' and attribute 2 is 'geo-term'. (George Washington Bridge: yes, yes, location; John Hancock Tower: yes, yes, location; Ronald Reagan Building: yes, yes, location; Azore Islands: no, yes, location; Michael Jackson: yes, no, person; Justin Bieber: yes, no, person; Lady Gaga: no, no, person; Adele: yes, no, person; Stalin: no, no, person.) Which attribute is more useful, and why?

سؤال Decision tree: مجموعة التدريب تصنّف الأسماء إلى location أو person. الخاصية 1 هي 'first name' والخاصية 2 هي 'geo-term'. أي خاصية أكثر فائدة ولماذا؟

Model answer:

Split on attribute 1 (first name): yes gives 3 locations and 3 persons (mixed); no gives 1 location and 2 persons (mixed). Both branches are impure, so it separates the classes poorly.

Split on attribute 2 (geo-term): yes gives 4 locations and 0 persons; no gives 0 locations and 5 persons. Both branches are pure.

Therefore attribute 2 (geo-term) is more useful: it perfectly separates the two classes, while attribute 1 leaves both branches mixed.

📍 المرجع: Lecture 03 — Quiz slide (decision tree)