NEURAL NETWORKS (MC459)

Lecture 2
Introduction to Neural Networks

Question Bank with Answers & Explanations

Calculation 6	Essay 12	MCQ 36

Course: **Neural Networks**

Lecture: **2 — Introduction to Neural Networks**

Instructor: **Dr. Amal Abd-Elazim**

Questions: **54** total

Part 1: Multiple Choice Questions (MCQ)

1. HIGH

1. What is the primary inspiration behind neural networks?

ما هو الإلهام الأساسي وراء الشبكات العصبية؟

A. The human brain

B. Statistical models

C. Computer architecture

D. Graph theory

CORRECT ANSWER: **A. The human brain**

الشرح: الإجابة الصحيحة هي العقل البشري لأن الشبكات العصبية بتقلد وظائف الدماغ المعقدة. الاختيارات التانية غلط: النماذج الإحصائية والإلكترونية مفيهاش فكرة المحاكاة البيولوجية للخلايا العصبية.

المرجع: *Lecture 2 — Slide 2 (What is a Neural Network?)*

2. HIGH

2. In biological neurons, the connection between two neurons is called:

في الخلايا العصبية البيولوجية، الاتصال بين خليتين عصبيتين بيتسمى:

A. Axon

B. Synapse

C. Dendrite

D. Nucleus

CORRECT ANSWER: **B. Synapse**

الشرح: الصحيح هو المشبق (Synapse) لأنه النقطة اللي بتحول الإشارة من خلية لأخرى. الـ Axon هو اللي بينقل الإشارة جوه الخلية، والـ Dendrite بيستقبل الإشارات، والـ Nucleus هو نواة الخلية.

المرجع: *Lecture 2 — Slide 3 (Neuron Abstraction)*

.3 HIGH

3. The term "synaptic efficacy" refers to:

مصطلح "synaptic efficacy" بيشير إلى:

A. The speed of electrical signals in the brain

B. The number of neurons in a network

C. How well a signal is passed from the presynaptic to the postsynaptic neuron

D. The chemical composition of a neuron

CORRECT ANSWER: **C. How well a signal is passed from the presynaptic to the postsynaptic neuron**

الشرح: الصحيح هو مدى كفاءة انتقال الإشارة من العصبون قبل المشبقي للعصبون بعد المشبقي. ده بيمثل فكرة الأوزان في الشبكات العصبية الاصطناعية. باقي الاختيارات بتعريفات تانية ملهاش علاقة بالكفاءة المشبقية.

المرجع: *Lecture 2 — Slide 3 (Neuron Abstraction)*

.4 HIGH

4. In an artificial neuron, what does the symbol wij represent?

في العصبون الاصطناعي، الرمز wij بيمثل إيه؟

A. The bias of neuron j

B. The activation function of neuron j

C. The input signal from neuron i

D. The connection weight from neuron i to neuron j

CORRECT ANSWER: **D. The connection weight from neuron i to neuron j**

الشرح: الصحيح هو وزن الاتصال من العصبون i للعصبون j، وده بيمثل الـ synaptic efficacy البيولوجية. الـ bias هو θj، ودالة التفعيل S(xj)، والإشارة هي si.

المرجع: *Lecture 2 — Slide 6 (Artificial Neuron)*

5. HIGH

5. The total input xj to an artificial neuron is computed as:

المدخل الكلي xj للعصبون الاصطناعي بيُحسب إزاي؟

A. A linear weighted aggregation of inputs modified by an internal threshold

B. A nonlinear function of all inputs

C. The product of all input signals

D. The maximum of all input signals

CORRECT ANSWER: **A. A linear weighted aggregation of inputs modified by an internal threshold**

الشرح: الصحيح هو تجميع خطي موزون للمدخلات متعدّل بحد داخلي θj. ده بيتكتب xj = Σ(wij*si) + θj. باقي الاختيارات غلط لأنها بتوصف دوال تانية (nonlinear, product, max).

المرجع: *Lecture 2 — Slide 6 (Artificial Neuron)*

6. HIGH

6. Which layer of a neural network is responsible for receiving raw data?

أي طبقة في الشبكة العصبية مسؤولة عن استقبال البيانات الخام؟

A. Hidden layer

B. Input layer

C. Output layer

D. Activation layer

CORRECT ANSWER: **B. Input layer**

الشرح: الصحيح هي طبقة الإدخال (Input Layer) لأنها بتستقبل البيانات الخام زي قيم البكسل. الطبقة المخفية بتعمل التحويلات، والمخرج بيطلع النتيجة النهائية.

المرجع: *Lecture 2 — Slide 7 (Structure)*

HIGH .7

7. What is the main role of the hidden layers in a neural network?

إيه هو الدور الأساسي للطبقات المخفية في الشبكة العصبية؟

A. To receive the raw input data

B. To produce the final prediction

C. To perform complex transformations and feature extraction

D. To store the training dataset

CORRECT ANSWER: **C. To perform complex transformations and feature extraction**

الشرح: الصحيح إنها بتعمل التحويلات المعقدة واستخلاص الميزات (feature extraction). الطبقة الأولى بتجيب البيانات الخام، والأخيرة بتطلع النتيجة النهائية، أما المخفية فبتتعامل مع التمثيلات الوسيطة.

المرجع: *Lecture 2 — Slide 7 (Structure)*

HIGH .8

8. What is the main purpose of applying an activation function in a neuron?

إيه هو الهدف الأساسي من تطبيق دالة التفعيل في العصبون؟

A. To compute the weighted sum of inputs

B. To initialize the connection weights

C. To reduce the number of parameters

D. To introduce non-linearity into the network

CORRECT ANSWER: **D. To introduce non-linearity into the network**

الشرح: الصحيح هو إدخال اللاخطية (non-linearity) عشان الشبكة تقدر تتعلم علاقات معقدة. لو مفيش دالة تفعيل، الشبكة هتفضل خطية مهما زودت طبقاتها. الجمع الموزون بيتعمل قبل التفعيل مش بيها.

المرجع: *Lecture 2 — Slide 9 (Neuron Function)*

9. HIGH

9. Which of the following is NOT one of the training stages mentioned in the lecture?

أي واحد من الآتي مش مرحلة من مراحل التدريب المذكورة في المحاضرة؟

A. Data compression

B. Forward propagation

C. Loss calculation

D. Backpropagation

CORRECT ANSWER: **A. Data compression**

الشرح: الصحيح هو ضغط البيانات لأنه مش جزء من التدريب. المراحل المذكورة هي: الانتشار الأمامي (Forward propagation)، حساب الخسارة (Loss calculation)، والانتشار الخلفي (Backpropagation) لتعديل الأوزان.

المرجع: *Lecture 2 — Slide 10 (Learning Process)*

10. HIGH

10. Which type of neural network is most suitable for image processing tasks?

أي نوع من الشبكات العصبية مناسب أكتر لمهام معالجة الصور؟

A. Recurrent Neural Network (RNN)

B. Convolutional Neural Network (CNN)

C. Feedforward Neural Network (FNN)

D. Single-layer Perceptron

CORRECT ANSWER: **B. Convolutional Neural Network (CNN)**

الشرح: الصحيح هو CNN لأنها مصممة للبيانات الشبكية زي الصور باستخدام الالتفاف. الـ RNN للبيانات المتسلسلة، والـ FNN للتدفق العام.

المرجع: *Lecture 2 — Slide 11 (Types)*

HIGH .11

11. Recurrent Neural Networks (RNNs) are best suited for:

الشبكات العصبية المتكررة (RNN) مناسبة أكتر لإيه؟

A. Image recognition tasks

B. Medical diagnosis only

C. Sequential data such as text or time series

D. Binary classification problems

CORRECT ANSWER: **C. Sequential data such as text or time series**

الشرح: الصحيح هو البيانات المتسلسلة زي النص أو السلاسل الزمنية لأنها بتدعم الاتصالات الراجعة. الصور بتتعامل معاها CNN، والتشخيص الطبي مش تطبيقها الأساسي.

المرجع: *Lecture 2 — Slide 11 (Types)*

HIGH .12

12. A Deep Neural Network (DNN) is defined as:

الشبكة العصبية العميقة (DNN) بتتعرّف إزاي؟

A. A network with no hidden layers

B. A network with exactly one hidden layer

C. A network used only for regression

D. A network with multiple hidden layers

CORRECT ANSWER: **D. A network with multiple hidden layers**

الشرح: الصحيح هي شبكة فيها عدة طبقات مخفية. كلمة Deep بتشير لعدد الطبقات المخفية. لو مفيش طبقات مخفية يبقى perceptron، ولو طبقة واحدة يبقى shallow network.

المرجع: *Lecture 2 — Slide 11 (Types)*

13. HIGH

13. In a Feedforward Neural Network (FNN), data flows:

في الشبكة العصبية التغذية الأمامية (FNN)، البيانات بتتدفق إزاي؟

A. In one direction only, with no loops

B. In multiple directions with loops

C. From the output layer back to the input layer

D. Randomly between all layers

CORRECT ANSWER: **A. In one direction only, with no loops**

الشرح: الصحيح في اتجاه واحد بس من غير حلقات. ده عكس الـ RNN اللي فيها حلقات واتصالات راجعة.

المرجع: *Lecture 2 — Slide 11 (Types)*

14. HIGH

14. According to the binary threshold function, the output S(xj) equals:

حسب دالة الحد الثنائي، المخرج S(xj) بيساوي:

A. -1 if xj < 0, and 1 if xj ≥ 0

B. 1 if xj ≥ 0, and 0 if xj < 0

C. A value between 0 and 1

D. The same value as the input xj

CORRECT ANSWER: **B. 1 if xj ≥ 0, and 0 if xj < 0**

الشرح: الصحيح: 1 لو xj ≥ 0، و0 لو xj < 0. ده بينشئ نظام ذو حالتين زي مفتاح ON/OFF. الخيار اللي بيقول -1 و1 ده بيشير لـ bipolar function مش binary.

المرجع: *Lecture 2 — Slide 16 (Binary Threshold Function)*

.15 HIGH

15. The binary threshold function is also referred to as a:

دالة الحد الثنائي بتُسمّى بردو:

A. Smooth logistic unit

B. Linear unit

C. Threshold logic unit

D. Gaussian unit

CORRECT ANSWER: **C. Threshold logic unit**

الشرح: الصحيح هو Threshold Logic Unit لأنها بتشتغل كوحدة منطق بحد. السموث لوجستيك ده وصف الـ Sigmoid، والـ Gaussian نوع تاني خالص.

المرجع: *Lecture 2 — Slide 16 (Binary Threshold Function)*

.16 HIGH

16. What happens to the sigmoidal activation function as λj approaches infinity?

إيه اللي بيحصل لدالة التفعيل السيجمويدية لما λj يقرب من اللانهاية؟

A. It becomes a linear function

B. It approaches the Gaussian function

C. It becomes unbounded

D. It approaches the binary threshold function

CORRECT ANSWER: **D. It approaches the binary threshold function**

الشرح: الصحيح إنها بتقرب من دالة الحد الثنائي لأن المنحدر بيبقى حاد جداً. ده استنتاج مهم اتكرر في المحاضرة. الخيارات التانية غلط لأن السيجمويد مش بيتحول لخطي ولا Gaussian.

المرجع: *Lecture 2 — Slide 20 (Sigmoidal Activation Function)*

HIGH .17

17. Which of the following properties correctly describes the sigmoidal activation function?

أي واحد من الآتي بيوصف دالة التفعيل السيجمويدية صح؟

A. Monotonic, continuous, and bounded

B. Non-monotonic and unbounded

C. Discontinuous and bounded

D. Linear and unbounded

CORRECT ANSWER: **A. Monotonic, continuous, and bounded**

الشرح: الصحيح: رتيبة (monotonic)، مستمرة (continuous)، ومحدودة (bounded) بين 0 و1. ده تلات خصائص مهمة اتذكروا في الشريحة. الـ Gaussian هي اللي non-monotonic.

المرجع: *Lecture 2 — Slide 20 (Sigmoidal Activation Function)*

HIGH .18

18. Which activation function is described as non-monotonic in the lecture?

أي دالة تفعيل وُصفت في المحاضرة بأنها non-monotonic؟

A. Sigmoid

B. Gaussian

C. Tanh

D. ReLU

CORRECT ANSWER: **B. Gaussian**

الشرح: الصحيح هو Gaussian لأن شكلها الجرسي بيخليها تطلع وتنزل (مش رتيبة). السيجمويد والتانهوك وReLU كلها رتيبة.

المرجع: *Lecture 2 — Slide 22 (Gaussian Activation Function)*

.19 HIGH

19. In the Gaussian activation function, what does the parameter σj represent?

في دالة التفعيل الـ Gaussian، البارامتر σj بيمثل إيه؟

A. The center of the function

B. The slope of the function

C. The Gaussian spread factor

D. The internal threshold

CORRECT ANSWER: **C. The Gaussian spread factor**

الشرح: الصحيح هو معامل الانتشار (spread factor) اللي بيحدد دالة حادة ولا منتشرة. الـ center هو cj، والـ slope خاص بالـ linear threshold.

المرجع: *Lecture 2 — Slide 22 (Gaussian Activation Function)*

.20 HIGH

20. The ReLU activation function is defined as:

دالة التفعيل ReLU بتتعرّف إزاي؟

A. S(x) = 1 / (1 + e^(-x))

B. S(x) = tanh(x)

C. S(x) = min(0, x)

D. S(x) = max(0, x)

CORRECT ANSWER: **D. S(x) = max(0, x)**

الشرح: الصحيح S(x) = max(0, x) - بترجع x لو موجب، و0 لو سالب. الخيار الأول ده السيجمويد، التاني التانهوك، والتالت غلط (min مش max).

المرجع: *Lecture 2 — Slide 24 (ReLU)*

HIGH .21

21. What is a major drawback of the ReLU activation function?

إيه هو العيب الأساسي لدالة ReLU؟

A. "Dead neurons" that may stay at zero forever

B. Computationally very slow

C. Suffers from vanishing gradient

D. Bounded output range

CORRECT ANSWER: **A. "Dead neurons" that may stay at zero forever**

الشرح: الصحيح هو ظاهرة "العصبونات الميتة" - لو خرج العصبون صفر، ممكن يفضل صفر للأبد. الـ ReLU سريعة (مش بطيئة)، بتحل مشكلة التلاشي (مش بتعاني منه)، ومش محدودة.

المرجع: *Lecture 2 — Slide 25 (ReLU Characteristics)*

HIGH .22

22. Which activation function outputs values in the range [-1, 1]?

أي دالة تفعيل بتطلع قيم في المدى [-1, 1]؟

A. Sigmoid

B. Tanh

C. ReLU

D. Softmax

CORRECT ANSWER: **B. Tanh**

الشرح: الصحيح هو Tanh (الظل الزائدي) لأنه بيخرج قيم بين -1 و1. السيجمويد بين 0 و1، وReLU بين 0 و∞، وSoftmax للاحتمالات.

المرجع: *Lecture 2 — Slide 26-27 (Comparison Table)*

HIGH .23

23. The sigmoid function is known to suffer from which gradient issue?

دالة السيجمويد معروفة بمعاناتها من مشكلة إيه في التدرج؟

A. Dying ReLU problem

B. Exploding gradient

C. Vanishing gradient

D. No gradient issues

CORRECT ANSWER: **C. Vanishing gradient**

الشرح: الصحيح هو تلاشي التدرج (vanishing gradient) لأن ميل السيجمويد بيقرب من صفر في الأطراف. الـ Dying ReLU مشكلة ReLU، والانفجار مش مشكلتها الأساسية.

المرجع: *Lecture 2 — Slide 26-27 (Comparison Table)*

HIGH .24

24. Which activation function is most commonly used in the hidden layers of deep networks?

أي دالة تفعيل مستخدمة أكتر في الطبقات المخفية للشبكات العميقة؟

A. Sigmoid

B. Tanh

C. Softmax

D. ReLU

CORRECT ANSWER: **D. ReLU**

الشرح: الصحيح هو ReLU لأنها سريعة وبسيطة وتحل مشكلة التلاشي. ده مذكور صراحةً في شريحة "When to Use Each". السيجمويد للتصنيف الثنائي في المخرج.

المرجع: *Lecture 2 — Slide 28 (When to Use Each)*

.25 HIGH

25. For binary classification, which activation function is typically used in the output layer?

للتصنيف الثنائي، أي دالة تفعيل بُستخدم عادةً في طبقة المخرج؟

A. Sigmoid

B. ReLU

C. Tanh

D. Linear

CORRECT ANSWER: **A. Sigmoid**

الشرح: الصحيح هو Sigmoid لأنها بتخرج قيمة بين 0 و1 تمثل احتمال. ReLU للطبقات المخفية، التانهوك لما محتاجين zero-centered.

المرجع: *Lecture 2 — Slide 28 (When to Use Each)*

.26 HIGH

26. According to the eight components of neural networks, how many types of neurons are there?

حسب المكونات الثمانية للشبكات العصبية، كم نوع من العصبونات موجود؟

A. Two

B. Three

C. Four

D. Five

CORRECT ANSWER: **B. Three**

الشرح: الصحيح 3 أنواع: Input (إدخال)، Hidden (مخفية)، Output (مخرج). ده اتذكر صراحةً في أول مكوّن من المكونات الثمانية.

المرجع: *Lecture 2 — Slides 30-31 (Eight Components)*

HIGH .27

27. Which type of neuron serves as the entry point to the network?

أي نوع من العصبونات بيشتغل كنقطة الدخول للشبكة؟

A. Hidden neuron

B. Output neuron

C. Input neuron

D. Bias neuron

CORRECT ANSWER: **C. Input neuron**

الشرح: الصحيح هو Input neuron لأنه بيستقبل البيانات أو المحفزات الخارجية من البيئة. الـ Hidden بتعمل العمليات الوسيطة، والـ Output بتطلع النتيجة.

المرجع: *Lecture 2 — Slides 30-31 (Eight Components)*

HIGH .28

28. The activation state vector X represents:

متجه حالة التفعيل X بيمثل إيه؟

A. The connection weights of the network

B. Only the input data values

C. The final predictions of the network

D. The activation levels of individual neurons

CORRECT ANSWER: **D. The activation levels of individual neurons**

الشرح: الصحيح: مستويات تفعيل العصبونات الفردية X = [x1, ..., xn]. ده المكوّن التاني من المكونات الثمانية. الأوزان والمدخلات والمخرجات مفاهيم تانية.

المرجع: *Lecture 2 — Slides 30-31 (Eight Components)*

.29 HIGH

29. An excitatory connection between two neurons:

الاتصال المثير (excitatory) بين خليتين عصبيتين بيعمل إيه؟

A. Increases the activation of the next neuron

B. Decreases the activation of the next neuron

C. Has no effect on activation

D. Resets the activation to zero

CORRECT ANSWER: **A. Increases the activation of the next neuron**

الشرح: الصحيح: بيزيد تفعيل العصبون التالي. ده عكس الـ Inhibitory (-) اللي بيقلل التفعيل. الـ Absent (0) مفيش اتصال أصلاً.

المرجع: *Lecture 2 — Slide 32 (Pattern of Connectivity)*

.30 HIGH

30. The activity aggregation rule is typically computed as:

قاعدة تجميع النشاط بتُحسب عادةً إزاي؟

A. The maximum of inputs and weights

B. The dot product of the input vector and the weight vector

C. The element-wise multiplication only

D. The concatenation of input and weight vectors

CORRECT ANSWER: **B. The dot product of the input vector and the weight vector**

الشرح: الصحيح هو الضرب النقطي (dot product / inner product) بين متجه المدخلات ومتجه الأوزان. ده بيحدد المدخل الكلي للعصبون قبل دالة التفعيل. باقي الطرق مش اللي اتعمل في المحاضرة.

المرجع: *Lecture 2 — Slide 32 (Activity Aggregation Rule)*

.31 HIGH

31. According to the eight components, the environment of a neural network can be:

حسب المكونات الثمانية، بيئة الشبكة العصبية ممكن تكون:

A. Only deterministic

B. Only stochastic

C. Either deterministic (noiseless) or stochastic (noisy)

D. Always noisy

CORRECT ANSWER: **C. Either deterministic (noiseless) or stochastic (noisy)**

الشرح: الصحيح إما deterministic (بلا ضوضاء) أو stochastic (فيها ضوضاء). ده المكوّن الثامن والأخير. الاتنين ممكنين مش واحد فيهم بس.

المرجع: *Lecture 2 — Slide 33 (Eight Components)*

.32 HIGH

32. A feedback (recurrent) architecture is characterized by:

المعمارية الراجعة (recurrent) بتتميز بـ:

A. Data flowing only in the forward direction

B. No connections between neurons

C. Only a single layer of neurons

D. Loops in the network due to feedback connections

CORRECT ANSWER: **D. Loops in the network due to feedback connections**

الشرح: الصحيح: وجود حلقات في الشبكة بسبب اتصالات راجعة. ده عكس الـ feedforward اللي مفيهاش حلقات.

المرجع: *Lecture 2 — Slide 34 (Architectures)*

HIGH .33

33. A network that maps vectors from one space to another, written as f: R^n → R^p, is called:

الشبكة اللي بتربط متجهات من فضاء لفضاء تاني (f: R^n → R^p) بتسمّى:

A. A heteroassociator

B. An autoassociator

C. A feedforward-only network

D. A stochastic network

CORRECT ANSWER: **A. A heteroassociator**

الشرح: الصحيح هو heteroassociator لأنه بيربط نمطين مختلفين (مدخل ≠ مخرج). الـ autoassociator بيربط النمط بنفسه.

المرجع: *Lecture 2 — Slide 35 (Neural Networks Generate Mappings)*

HIGH .34

34. An autoassociator is a network that:

الـ autoassociator هو شبكة بتعمل إيه؟

A. Maps two different patterns to each other

B. Associates a single pattern with itself

C. Has no hidden layers at all

D. Always uses the ReLU activation

CORRECT ANSWER: **B. Associates a single pattern with itself**

الشرح: الصحيح: بتربط نمط واحد في R^n بنفسه (لما العصبونات تتصل على نفسها). ده عكس الـ heteroassociator اللي بيربط نمطين مختلفين.

المرجع: *Lecture 2 — Slide 35 (Neural Networks Generate Mappings)*

.35 HIGH

35. In the linear threshold function, the slope parameter αj equals:

في دالة الحد الخطي، معامل الميل αj بيساوي:

A. xm

B. xm / 2

C. 1 / xm

D. 0

CORRECT ANSWER: **C. 1 / xm**

الشرح: الصحيح αj = 1/xm. ده مذكور صراحةً في شريحة الـ Linear Threshold. xm هي قيمة الذروة اللي بعدها المخرج بيبقى 1.

المرجع: *Lecture 2 — Slide 19 (Linear Threshold Activation Function)*

.36 MEDIUM

36. The signal of a stochastic neuron is assumed to be:

إشارة العصبون العشوائي (stochastic neuron) بتفترض إنها:

A. Continuous only

B. Always positive

C. Always equal to zero

D. Two-state: {0, 1} or {-1, 1}

CORRECT ANSWER: **D. Two-state: {0, 1} or {-1, 1}**

الشرح: الصحيح ذو حالتين إما {0, 1} أو {-1, 1}، والعصبون بيتبدل بينهم بدالة احتمالية P(xj). ده عكس الدوال المستمرة زي السيجمويد.

المرجع: *Lecture 2 — Slide 23 (Stochastic Neurons)*

Part 2: Essay Questions

Essay 1. HIGH

1. Define a neural network and explain how it relates to the human brain.

عرّف الشبكة العصبية واشرح علاقتها بالعقل البشري.

A neural network is a machine learning model that mimics the complex functions of the human brain. It consists of interconnected nodes called neurons that process data, learn patterns, and enable tasks such as pattern recognition, decision making, and prediction.
Relation to the brain:
- Biological neurons send signals by converting them from electrical to chemical and back to electrical.
- The connection between two neurons is called a synapse, and its effectiveness is called synaptic efficacy.
- In the artificial model, connection weights wij model these synaptic efficacies.
- The internal threshold θj models the neuron's firing threshold.
Thus, the artificial neuron is an abstract mathematical model inspired by biological neurons, capturing the idea of weighted signal aggregation and threshold-based firing.

المرجع: *Lecture 2 — Slides 2-3 (Neural Network & Neuron Abstraction)*

Essay 2. HIGH

2. Explain the structure of a neural network and the function of each layer.

اشرح بنية الشبكة العصبية ووظيفة كل طبقة.

```
A neural network is organized into layers of interconnected nodes (neurons).
It typically includes three types of layers:
1. Input Layer: Receives the raw data (e.g., pixel values of an image) and
serves as the entry point to the network.
2. Hidden Layers: Perform complex transformations and feature extraction
from the input data. They learn intermediate representations that help solve
the task.
3. Output Layer: Produces the final result, such as a class label or a
predicted numerical value.
Each neuron computes a weighted sum of its inputs, adds a bias, and passes
the result through an activation function (e.g., ReLU, sigmoid, tanh) to
introduce non-linearity.
```

المرجع: *Lecture 2 — Slides 7-9 (Structure, Neuron Function)*

Essay 3. HIGH

3. Describe the learning (training) process of a neural network in detail.

اشرح عملية التعلم (التدريب) للشبكة العصبية بالتفصيل.

```
Neural networks learn through a process called training, which involves
three main stages:
1. Forward Propagation: The network computes its output from the given
inputs by passing data through the layers and applying weights, biases, and
activation functions.
2. Loss Calculation: The error between the predicted output and the actual
(target) output is measured using a loss function.
3. Backpropagation: The network adjusts its weights to minimize the error.
This is typically done using optimization algorithms such as gradient
descent, which updates the weights in the direction that reduces the loss.
These three steps are repeated over many training examples until the
network's predictions reach an acceptable accuracy.
```

المرجع: *Lecture 2 — Slide 10 (Learning Process)*

Essay 4. HIGH

4. Compare the four types of neural networks (FNN, CNN, RNN, DNN) in terms of data flow and use cases.

قارن الأنواع الأربعة للشبكات العصبية (FNN، CNN، RNN، DNN) من حيث تدفق البيانات وحالات الاستخدام.

```
1. Feedforward Neural Network (FNN): Data flows in one direction only (no loops). Used for general tasks where data has no spatial or temporal structure.
2. Convolutional Neural Network (CNN): Specialized for image processing and grid-like data; uses convolution operations to detect spatial features.
3. Recurrent Neural Network (RNN): Suitable for sequential data such as text or time series; uses feedback connections so previous outputs influence current computation.
4. Deep Neural Network (DNN): A network with multiple hidden layers; depth allows it to model very complex hierarchical features. DNN is a broad term that can include deep FNNs, CNNs, or RNNs.
```

المرجع: *Lecture 2 — Slide 11 (Types)*

Essay 5. HIGH

5. What is an activation (signal) function in a neural network and why is it important? List the common types mentioned in the lecture.

إيه هي دالة التفعيل (الإشارة) في الشبكة العصبية وليه مهمة؟ اذكر الأنواع الشائعة المذكورة في المحاضرة.

```
After computing the total input xj, the neuron's activation is passed
through an activation function (also called a signal function) denoted by
S(x), where sj = S(xj). This function determines the output signal of the
neuron.
Importance: The activation function introduces non-linearity, which is
essential for the network to learn complex, non-linear patterns. Without it,
stacking layers would still produce only linear transformations.
Common types from the lecture:
- Binary Threshold Function: outputs 0 or 1 based on a threshold.
- Linear Threshold Function: combines linearity and thresholding.
- Sigmoid Function: smooth, non-linear, used in logistic regression.
- Gaussian Function: bell-shaped, used in radial basis function networks.
- Probabilistic Function: outputs a probability value.
Modern additions: ReLU (max(0, x)), Softmax (multi-class classification),
and Tanh (range [-1, 1]).
```

المرجع: *Lecture 2 — Slides 13-15 (Activation Functions)*

Essay 6. HIGH

6. Explain the binary threshold activation function and how a neuron decides to fire based on the threshold θj.

اشرح دالة التفعيل الثنائية (binary threshold) وإزاي العصبون بيقرر يطلق إشارة بناءً على الحد θj.

```
The binary threshold function is one of the simplest activation functions.
It works as follows:
- S(xj) = 1 if xj >= 0
- S(xj) = 0 if xj < 0
Key characteristics: it produces outputs of either 0 or 1 only, creating a
two-state system (like an ON/OFF switch). This is why it is called a
threshold logic unit.
Threshold interpretation:
- The net activation is computed as xj = qj + θj, where qj = Σ(wij * si) is
the weighted sum and θj is the internal threshold (bias).
- The neuron fires (outputs +1) when xj >= 0, which means qj >= -θj.
- The neuron outputs 0 when qj < -θj.
In simple terms, the neuron compares the weighted input qj against the
negative of the bias (-θj) to decide whether to fire.
```

المرجع: *Lecture 2 — Slides 16-18 (Binary Threshold & Interpretation)*

Essay 7. HIGH

7. Compare ReLU, Sigmoid, and Tanh activation functions based on output range, zero-centered property, non-linearity, gradient issues, and speed.

قارن دوال التفعيل ReLU و Sigmoid و Tanh بناءً على مدى المخرج، خاصية التمركز حول الصفر، اللاخطية، مشاكل التدرج، والسرعة.

```
Comparison table (from the lecture):
| Property         | ReLU        | Sigmoid       | Tanh          |
| Output Range     | [0, ∞)      | (0, 1)        | (-1, 1)       |
| Zero-centered    | No          | No            | Yes           |
| Non-linear       | Yes         | Yes           | Yes           |
| Gradient Issues  | Dying ReLU  | Vanishing Gradient | Vanishing Gradient |
| Speed            | Fast        | Slower        | Slower        |
Key points:
- ReLU is the fastest and helps reduce the vanishing gradient problem, but it can suffer from 'dead neurons'.
- Sigmoid and Tanh are smooth but suffer from vanishing gradients, especially in deep networks.
- Tanh is preferred over Sigmoid for hidden layers when zero-centered output is helpful.
```

المرجع: *Lecture 2 — Slides 26-27 (Comparison Table)*

Essay 8. HIGH

8. Explain when to use ReLU, Sigmoid, and Tanh in a neural network.

اشرح متى نستخدم ReLU و Sigmoid و Tanh في الشبكة العصبية.

```
When to use each activation function:
1. ReLU: The most common choice. Best for hidden layers in deep networks
because it is fast to compute and helps reduce the vanishing gradient
problem.
2. Sigmoid: Used for binary classification in the output layer, where the
output needs to be interpreted as a probability in the range (0, 1).
3. Tanh: Can be better than Sigmoid for hidden layers when zero-centered
output is helpful, because its output is in the range (-1, 1), which often
makes optimization easier.
The right choice depends on the task: hidden layers usually use ReLU, while
the output layer depends on whether the task is binary classification
(Sigmoid), multi-class (Softmax), or regression (Linear).
```

المرجع: *Lecture 2 — Slide 28 (When to Use Each)*

Essay 9. HIGH

9. List and briefly explain the eight components of a neural network.

اذكر واشرح بإيجاز المكونات الثمانية للشبكة العصبية.

```
The eight components of a neural network are:
1. Neurons: Come in three types - Input (receive external data), Hidden (compute intermediate functions and extract features), Output (generate the final result).
2. Activation state vector: A vector X = [x1, ..., xn] of the activation levels of individual neurons.
3. Signal function (activation function): Generates the output signal of the neuron based on its activation.
4. Pattern of Connectivity: Defines how neurons are connected. Connections can be Excitatory (+), Inhibitory (-), or Absent (0).
5. Activity Aggregation Rule: Explains how a neuron combines input signals, typically as the dot product of the input vector and the weight vector.
6. Activation rule: Determines the new activation level of a neuron based on its current activation and external inputs.
7. Learning rule: Modifies connection strengths based on external stimuli and network performance, aiming to improve the latter.
8. Environment: The environment in which the network operates - either deterministic (noiseless) or stochastic (noisy).
```

المرجع: *Lecture 2 — Slides 30-33 (Eight Components)*

Essay 10. MEDIUM

10. Describe the three types of connectivity patterns (excitatory, inhibitory, absent) and their effects.

صف الأنواع الثلاثة من أنماط الاتصال (مثير، مثبط، غائب) وتأثيرها.

```
The pattern of connectivity defines how neurons are connected in the
network. Each connection between neurons can have one of three effects:
1. Excitatory (+): Increases the activation of the next neuron. A positive
weight strengthens the signal passed forward.
2. Inhibitory (-): Decreases the activation of the next neuron. A negative
weight weakens or suppresses the signal.
3. Absent (0): No connection between the neurons. The signal is not
transmitted at all.
These three patterns determine the structure of the network and influence
which neurons affect which others, thereby shaping the computations the
network can perform.
```

المرجع: *Lecture 2 — Slide 32 (Pattern of Connectivity)*

Essay 11. HIGH

11. Compare feedforward and feedback (recurrent) architectures.

قارن بين المعماريات الـ feedforward والـ feedback (recurrent).

```
Local groups of neurons can be connected in either architecture:
1. Feedforward Architecture:
   - The network has no loops.
   - Data flows only in the forward direction, from input to output.
   - Examples: FNN, CNN.
2. Feedback (Recurrent) Architecture:
   - Loops occur in the network due to feedback connections.
   - The output of a neuron can influence its own future computation or the
computation of neurons in earlier layers.
   - Suitable for sequential data such as text or time series.
   - Example: RNN.
The key difference is the presence or absence of loops, which determines
whether the network has memory of previous inputs.
```

المرجع: *Lecture 2 — Slide 34 (Architectures)*

Essay 12. HIGH

12. Explain the difference between heteroassociators and autoassociators.

اشرح الفرق بين الـ heteroassociator والـ autoassociator.

```
Neural networks generate mappings between vector spaces:
1. Heteroassociator:
   - A multilayered network that associates vectors from one space to
vectors of another space.
   - It maps two different patterns - one as input and another as output.
   - Mathematically: f: R^n → R^p (where n and p are different).
2. Autoassociator:
   - When neurons in a single field connect back onto themselves.
   - The network associates a single pattern in R^n with itself.
   - Used for tasks like pattern completion, where the network reconstructs
a stored pattern from a partial or noisy version.
Key difference: Heteroassociators map input to a different output, while
autoassociators map an input to itself.
```

المرجع: *Lecture 2 — Slide 35 (Neural Networks Generate Mappings)*

Part 3: Calculation Problems

Calculation 1. HIGH

Calculation 1. A neuron receives two input signals s1 = 2 and s2 = -1 with weights w1j = 0.5 and w2j = 0.8, and an internal threshold θj = -0.5. Using the binary threshold activation function, determine whether the neuron fires (output = 1) or not (output = 0).

مسألة 1. عصبون بيستقبل إشارتين s1 = 2 و s2 = -1 بأوزان w1j = 0.5 و w2j = 0.8 وحد داخلي θj = -0.5. باستخدام دالة الحد الثنائي، حدد هل العصبون هيطلق إشارة (مخرج = 1) ولا لأ (مخرج = 0).

```
Step 1: Compute the net input xj.
xj = Σ(wij * si) + θj
xj = (w1j * s1) + (w2j * s2) + θj
xj = (0.5)(2) + (0.8)(-1) + (-0.5)
xj = 1.0 - 0.8 - 0.5
xj = -0.3
Step 2: Apply the binary threshold function.
S(xj) = 1 if xj >= 0, else 0
Since xj = -0.3 < 0, the neuron does NOT fire.
Output = 0.
```

المرجع: *Lecture 2 — Slides 16-18 (Binary Threshold & Interpretation)*

Calculation 2. HIGH

Calculation 2. Compute the output of the sigmoidal activation function S(xj) = 1 / (1 + e^(-λj * xj)) for a neuron with net input xj = 0 and gain factor λj = 1.

*مسألة 2. احسب مخرج دالة التفعيل السيجمويدية S(xj) = 1 / (1 + e^(-λj * xj)) لعصبون بمدخل xj = 0 ومعامل كسب λj = 1.*

```
Formula: S(xj) = 1 / (1 + e^(-λj * xj))
Given: xj = 0, λj = 1
Substitute:
S(0) = 1 / (1 + e^(-1 * 0))
S(0) = 1 / (1 + e^0)
Since e^0 = 1:
S(0) = 1 / (1 + 1)
S(0) = 1 / 2
S(0) = 0.5
Interpretation: When the net input is zero, the sigmoid outputs 0.5 (its
midpoint). This is the central property of the sigmoid function.
```

المرجع: *Lecture 2 — Slide 20 (Sigmoidal Activation Function)*

Calculation 3. HIGH

Calculation 3. A neuron has a net input xj = -3.5. Compute the output of the ReLU activation function.

مسألة 3. عصبون بمدخل xj = -3.5. احسب مخرج دالة التفعيل ReLU.

```
Formula: ReLU(xj) = max(0, xj)
Given: xj = -3.5
Substitute:
ReLU(-3.5) = max(0, -3.5)
Since 0 > -3.5, the maximum is 0.
Output = 0.
Note: This illustrates the 'dead neuron' issue - when the input is negative,
ReLU outputs 0, and the gradient is also 0, so the neuron may not learn.
```

المرجع: *Lecture 2 — Slides 24-25 (ReLU)*

Calculation 4. HIGH

Calculation 4. Given a linear threshold activation function with xm = 2 (so αj = 1/xm = 0.5), compute the output S(xj) for: (a) xj = -1, (b) xj = 1, (c) xj = 3.

مسألة 4. بدالة الحد الخطي xm = 2 (يكون αj = 1/xm = 0.5)، احسب المخرج S(xj) لـ: (أ) xj = -1، (ب) xj = 1، (ج) xj = 3.

```
Function definition:
S(xj) = 0           if xj <= 0
S(xj) = αj * xj     if 0 < xj < xm
S(xj) = 1           if xj >= xm
Given: xm = 2, αj = 0.5
(a) xj = -1: since xj <= 0, S = 0
(b) xj = 1: since 0 < 1 < 2, S = αj * xj = 0.5 * 1 = 0.5
(c) xj = 3: since xj >= xm (3 >= 2), S = 1
Summary: (a) 0, (b) 0.5, (c) 1
```

المرجع: *Lecture 2 — Slide 19 (Linear Threshold Activation Function)*

Calculation 5. HIGH

Calculation 5. A neuron receives three input signals s1 = 1, s2 = 1, s3 = 0 with weights w1j = 1, w2j = 1, w3j = 1 and a bias θj = -1.5. Using the binary threshold activation function: (a) Compute the weighted sum qj = Σ(wij * si). (b) Compute the net activation xj = qj + θj. (c) Determine whether the neuron fires.

مسألة 5. عصبون بيستقبل 3 إشارات s1 = 1، s2 = 1، s3 = 0 بأوزان w1j = 1، w2j = 1، w3j = 1 وحد θj = -1.5. بدالة الحد الثنائي: (أ) احسب المجموع الموزون qj. (ب) احسب التفعيل الكلي xj. (ج) حدد هل العصبون هيطلق.

```
(a) Compute the weighted sum qj:
qj = Σ(wij * si) = (w1j * s1) + (w2j * s2) + (w3j * s3)
qj = (1)(1) + (1)(1) + (1)(0)
qj = 1 + 1 + 0
qj = 2
(b) Compute the net activation xj:
xj = qj + θj
xj = 2 + (-1.5)
xj = 0.5
(c) Apply the binary threshold function:
Since xj = 0.5 >= 0, the neuron fires. Output = 1.
Alternative check: qj >= -θj → 2 >= 1.5 → True → fires.
```

المرجع: *Lecture 2 — Slide 18 (Interpretation of Threshold)*

Calculation 6. HIGH

Calculation 6. Compute the output of the tanh activation function for xj = 0. Use the formula tanh(x) = (e^x - e^(-x)) / (e^x + e^(-x)).

مسألة 6. احسب مخرج دالة التفعيل tanh لـ xj = 0. استخدم القانون tanh(x) = (e^x - e^(-x)) / (e^x + e^(-x)).

```
Formula: tanh(x) = (e^x - e^(-x)) / (e^x + e^(-x))
Given: xj = 0
Substitute:
tanh(0) = (e^0 - e^(-0)) / (e^0 + e^(-0))
Since e^0 = 1 and e^(-0) = 1:
tanh(0) = (1 - 1) / (1 + 1)
tanh(0) = 0 / 2
tanh(0) = 0
Interpretation: When the input is zero, tanh outputs 0. This is why tanh is
called zero-centered, unlike sigmoid which outputs 0.5 at the midpoint.
```

المرجع: *Lecture 2 — Slide 26 (Tanh Activation Function)*